Modelo de Predição:

Ocorrências de ATR graves em MG na BR 381

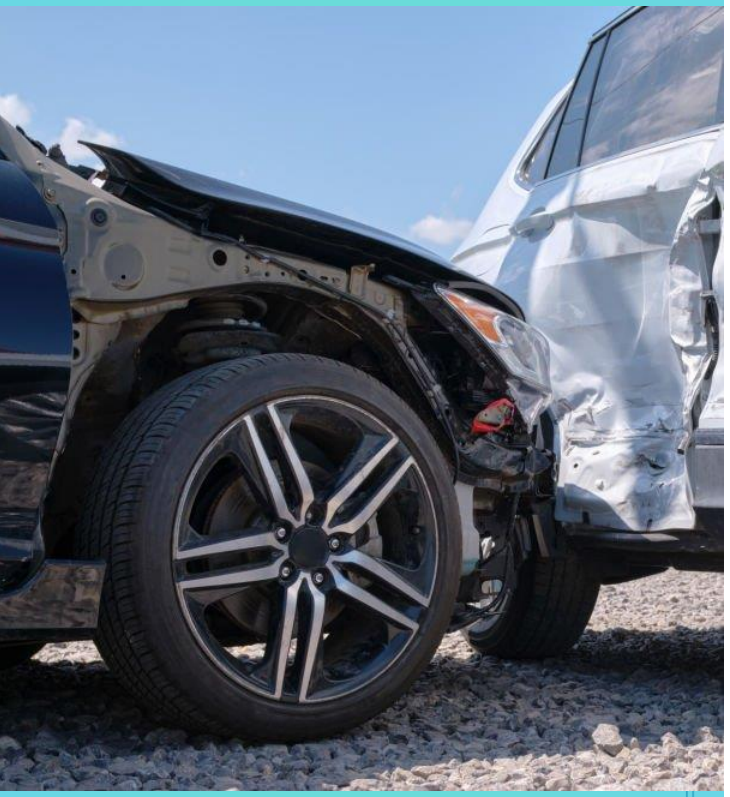
07/10/2024

FIA BUSINESS SCHOOL

lab.data



PÓS-GRADUAÇÃO ANALYTICS E INTELIGÊNCIA ARTIFICIAL – DATA-SCIENCE



Nome do Aluno:
Jéssica Priscila de Oliveira Martins

Coordenadores:
Profª Drª Alessandra de Álvila Montini
Profª Dr. Adolpho Walter Pimazoni Canton

FIA BUSINESS SCHOOL lab.data

Agenda

1. Metodologia de Análise de Dados
2. Objetivo do Trabalho
3. Contextualização do Problema
4. Base de Dados
    i. Bases originais
    ii. Filtros
    iii. Principais variáveis
5. Análise Exploratória de Dados
    i. Análise Univariada
    ii. Análise Bivariada
6. Modelagem com Estatística Tradicional
7. Modelagem com Inteligência Artificial
    i. Machine Learning
    ii. Deep Learning
8. Comparativo dos Modelos
9. Conclusões
10. Sugestão para Trabalhos Futuros

FIA BUSINESS SCHOOL lab.data

@2020 FIA LABDATA. Copyright all rights reserved.

1. Metodologia de análise de dados

Planejamento → Análise Exploratória → Modelagem Estatística → Algoritmos de Inteligência Artificial → Conclusões

Definição do problema

- Objetivos do Trabalho
- Contextualização do Problema
- Base de dados
- Principais Variáveis

Análise preliminar

- Medidas resumo
- Análise de *outliers*
- Análise de *missings*
- Tratamento dos dados
- Validação com a área de negócios sobre a consistência das informações

Ajuste e Avaliação Modelo

- Regressão Logística

Ajuste e Avaliação dos Modelos

- **Machine Learning:**
  - Regressão Logística
  - Cat Boost
  - XGBoost
- **Deep Learning:**
  - Redes Densas
  - CNN
  - LSTM

Considerações Finais

- Comparação entre as técnicas utilizadas
- Validação dos resultados
- Escolha da técnica mais adequada

@2020 FIA LABDATA. Copyright all rights reserved.

Metodologia de análise de dados

Planejamento | Análise Exploratória | Modelagem Estatística | Algoritmos de Inteligência Artificial | Conclusões

Definição do problema

- Objetivos do Trabalho
- Contextualização do Problema
- Base de dados
- Principais Variáveis

Análise preliminar

- Medidas resumo
- Análise de *outliers*
- Análise de *missings*
- Tratamento dos dados
- Validação com a área de negócios sobre a consistência das informações

Ajuste e Avaliação Modelo

- Regressão Logística

Ajuste e Avaliação dos Modelos

- **Machine Learning:**
  - Regressão Logística
  - Cat Boost
  - XGBoost
- **Deep Learning:**
  - Redes Densas
  - CNN
  - LSTM

Considerações Finais

- Comparação entre as técnicas utilizadas
- Validação dos resultados
- Escolha da técnica mais adequada

@2020 FIA LABDATA. Copyright all rights reserved.



2. Objetivo do Trabalho

O objetivo do trabalho é aplicar a **predição dessas ocorrências de ATR (acidente de trânsito nas rodovias) com risco mais elevado (feridos graves ou mortos) em MG na BR 381.**

Foi realizado uma análise exploratória, utilizando **fatores descritivos** dos eventos, tais como: período do dia, situação meteorológica, zona, traçado da via, sentido da via, tipo da pista, tipo e causa do acidente, br e **fatores quantitativos** (pessoas, veículos), considerando o histórico das ocorrências (de Janeiro/2022 a Outubro/2023) e então construído **um modelo de predição utilizando modelos estatísticos** aplicado em Novembro/2023 para verificar a performance do modelo (out-of-time).

A partir disso, foram realizadas predições utilizando **algoritmos de Inteligência Artificial (Machine e Deep Learning)**, que selecionaram as **características mais relevantes, tendências nos dados** nos permitindo predizer ocorrências.

FIA BUSINESS SCHOOL lab.data



3. Contextualização do Problema

A Polícia Rodoviária Federal é detentora da informação referente as **ocorrências de acidentes de trânsitos** e em meio ao acompanhamento e analise identificaram que além de Minas Gerais ser o top 1 em ATR (acidentes de trânsito nas rodovias) , o mesmo ocorre na BR 381 de Minas Gerais.

Visando uma **nova estratégia para a Operação** (onde ocorre fiscalização nas rodovias, policiais patrulham a área com maiores ocorrências com o objetivo de conter alvoroços e imprudências) e ter a dimensão da necessidade de acionamento de outras equipes como SAMU ou BOMBEIROS, além de colaborar com o SAMU para dar uma visibilidade da possibilidade de ocorrências mais críticas , contrataram uma **Consultoria** para realizar um estudo com os dados histórico das ocorrências (de Janeiro/2022 a Outubro/2023) , com a finalidade de **identificar as características dos locais mais ofensores** no Estado de Minas Gerais na BR 381 e então **predizer a possibilidade do evento ocorrer ou não em casos de ocorrências com feridos graves ou mortes.**

Desta maneira o modelo auxiliará a Policia Rodoviária Federal a direcionarem suas ações com o público mais específico e com mais coerência a quantidade de policias e equipes envolvidas e necessárias destinados para fiscalização e apoio posterior.

FIA BUSINESS SCHOOL lab.data

3. Contextualização do Problema

MENU g1 MINAS GERAIS

BR-381: Conheça a rodovia que registrou mais de 2 mil acidentes só neste ano

A rodovia percorre Minas, São Paulo e Espírito Santo e possui mais de 1000 km de extensão. Governo quer leiloar trecho entre BH e Governador Valadares, onde fica parte conhecida como 'rodovia da morte'.

Por Rafaela Mansur, g1 Minas — Belo Horizonte
02/12/2023 06h00 · Atualizado há um mês



Veículos ficaram destruídos em acidente na Serra de Igarapé, no dia 27 de novembro — Foto: Carlos Eduardo Alvim/ TV Globo

Mais de **440** pessoas morreram em acidentes na BR-381, em Minas Gerais, nos últimos três anos. Somente entre janeiro de 2021 e outubro de 2023, aproximadamente **7 mil** acidentes foram registrados na rodovia, segundo dados da Polícia Rodoviária Federal (PRF).

Reportagem em 02-12-2023
link

Seções ESTADO DE MINAS Gerais Assine

BRs registram menos acidentes, mas total de mortos e feridos sobe

Em Minas Gerais, a BR-381liderou os óbitos em 2022, seguida pela BR-040. Velocidade inadequada é principal causa dos desastres, apontam dad da PRF

Mateus Parreiras
24/02/2023 04:00 · atualizado 24/02/2023 16:23

COMPARTILHE SIGA NO Google News





Aqui na Uninter sua nota do ENEM vale uma bolsa de até 100% de Desconto.

Grupo UNINTER Abrir

MAIS LIDAS

1 07:00 - 18/05/2013 - Compartilhe
Primeira hidrelétrica do país foi construída em M há mais de 100 anos

2 15:49 - 08/06/2022 - Compartilhe
Risco geológico em BH: saiba onde serão feitas para áreas de encostas

Reportagem em 24-02-2023
link

@2020 FIA LABDATA. Copyright all rights reserved.

4.i. Base Original



Visão da base

- Ocorrências de acidente de trânsito nas rodovias brasileiras. Tabela unificada com dados de 01/22 a 10/23
- De um total de 25 colunas, adicionei 7 colunas e removi 13 colunas , totalizando 19 colunas.
- De um total de 125.563 registros, ao filtrar o Estado de MG > BR 381 reduzi para 4.605 registros.
- Fonte de dados: Site Gov.br > Policia Rodoviária Federal > Acidentes : LINK

Inclusão

- Ano_mês_ocorrência, mês_ocorrência, a partir da data da ocorrência
- Região, a partir da UF
- Periodo_dia a partir do horário
- Causa_acidente_agg, a partir da causa_acidente
- Tipo_acidente_categ a partir do tipo_acidente
- Houve Mortes, a partir da coluna mortos
- Zona, a partir da coluna uso_solo

Exclusão

- Colunas que não são necessárias na base, pois contem divergência, ou foram categorizadas, ou causariam conflito com a variável target: (horario, km, municipio, causa_acidente, tipo_acidente, classificação_acidente, fase_dia, uso_solo ,mortos, feridos_leves, feridos_graves, ilesos, ignorados, feridos)

Período de Análise

Histórico (22meses): Jan/2022 a Out/2023
Previsão: Nov/23 out of time (Regressão Logística Tradicional)

@2020 FIA LABDATA. Copyright all rights reserved.

4.ii. Filtros

Base Original
125.563 ocorrências

Base de partida

Base original unificando as ocorrências desde 2022 a 10/23 com 125.563 e 25 variáveis.

Transformação na Base
125.563 ocorrências

Inclusão e Exclusão de colunas

Para visualizar melhor os dados, foi adicionado colunas como :ano_mês, mês, periodo_dia, região, causa_acidente_agg, tipo_acidente_categ, houve morte, zona. Além disso foi removido as colunas que não seriam necessárias , totalizando 19 colunas e 125.563 ocorrências.

Higienização da Base
4.605 ocorrências

Base Filtrada

Considerando somente as ocorrências do Estado de Minas Gerais na BR 381, totalizando 4.605 linhas e 19 variáveis.

Base Final
4.605 linhas

Base final

A base foi separada para treino (3.223 linhas) e teste (1.382 linhas) do modelo. Considerando somente as variáveis 5 variáveis que foram significativas no Modelo de Regressão Logística Tradicional e ML e total de 13 variáveis para DL.

@2020 FIA LABDATA. Copyright all rights reserved.

4.iii. Principais variáveis

As **5 variáveis explicativas** e a **variável resposta** que foram consideradas no Modelo Escolhido.
Para visualizar o dicionário de dados clique no ícone ao lado



Variáveis Identificação

- Causa do acidente agg
- Tipo do acidente categ



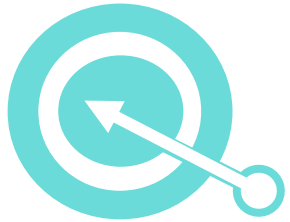
Variável descritiva

- Tipo pista



Variável quantitativa

- Veículos
- Pessoas



Variável Resposta

Target:
1 = ocorrência com feridos graves ou mortes
0 = ocorrência sem feridos graves ou mortes

@2020 FIA LABDATA. Copyright all rights reserved.

Metodologia de análise de dados

Planejamento | **Análise Exploratória** | Modelagem Estatística | Algoritmos de Inteligência Artificial | Conclusões

Definição do problema

- Objetivos do Trabalho
- Contextualização do Problema
- Base de dados
- Principais Variáveis

Análise preliminar

- Medidas resumo
- Análise de *outliers*
- Análise de *missings*
- Tratamento dos dados
- Validação com a área de negócios sobre a consistência das informações

Ajuste e Avaliação Modelo

- Regressão Logística

Ajuste e Avaliação dos Modelos

- **Machine Learning:**
  - Regressão Logística
  - Cat Boost
  - XGBoost
- **Deep Learning:**
  - Redes Densas
  - CNN
  - LSTM

Considerações Finais

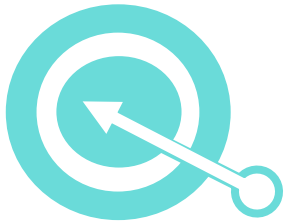
- Comparação entre as técnicas utilizadas
- Validação dos resultados
- Escolha da técnica mais adequada

@2020 FIA LABDATA. Copyright all rights reserved.

5.i. Raio-X da base

ANÁLISE EXPLORATÓRIA | UNIVARIADA

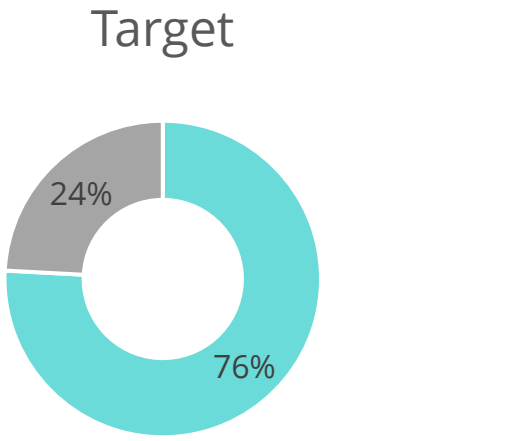
Das 4.605 ocorrências em Minas Gerais na BR 381 , 24% tiveram feridos graves ou mortes.



Variável Resposta

Target:
1 = ocorrência com feridos graves ou mortes

0 = ocorrência sem feridos graves ou mortes



Demais análises Univariada detalhadas

@2020 FIA LABDATA. Copyright all rights reserved.

5.ii. Raio-X do Problema de Negócio

ANÁLISE EXPLORATÓRIA | BIVARIADA

Persona Target 1

- Em média **24%(51) das ocorrências** de MG na BR 381 possuem feridos graves ou mortos.
- **75%** das ocorrências envolvem até **3 pessoas** e **2 veículos.**
- A causa de acidente com mais ocorrências nesta característica é **Fator Humano (26% 950 ocorrências)**
- Sendo o tipo de acidente mais ofensor **Atropelamento (129% 61 ocorrências)**
- Já a variável **condição meteorológica** por não explicar muito a variável resposta e ter como top 1 o missing value, foi descartada do modelo.
- E o tipo de pista mais propício mencionado nas ocorrências é **Tipo de pista Simples (38% 116 ocorrências)**



@2020 FIA LABDATA. Copyright all rights reserved.

5.ii. Análise das Variáveis explicativas x Variavel resposta

ANÁLISE EXPLORATÓRIA | BIVARIADA



Principais variáveis que explicam o evento de ocorrência com feridos graves ou mortos:

Variável Explicativa	Intepretação em relação a variável reposta
Pessoas	25%(Q1) da base no target = 1 tem 2 pessoas envolvidas
Veículos	A mediana (50%) da base no target = 1 tem 2 veículos envolvidos
Causa acidente agg	Fator Humano e Fator Via/natureza
Tipo pista	Tipo de Pista Simples
Tipo acidente categ	Atropelamento

Demais analises bivariada detalhada

Todas as informações foram validadas por e-mail com a PRF(Polícia Rodoviária Federal).

@2020 FIA LABDATA. Copyright all rights reserved.

Metodologia de análise de dados

Planejamento → Análise Exploratória → Modelagem Estatística → Algoritmos de Inteligência Artificial → Conclusões

Definição do problema

- Objetivos do Trabalho
- Contextualização do Problema
- Base de dados
- Principais Variáveis

Análise preliminar

- Medidas resumo
- Análise de *outliers*
- Análise de *missings*
- Tratamento dos dados
- Validação com a área de negócios sobre a consistência das informações

Ajuste e Avaliação Modelo

- Regressão Logística

Ajuste e Avaliação dos Modelos

- **Machine Learning:**
  - Regressão Logística
  - Cat Boost
  - XGBoost
- **Deep Learning:**
  - Redes Densas
  - CNN
  - LSTM

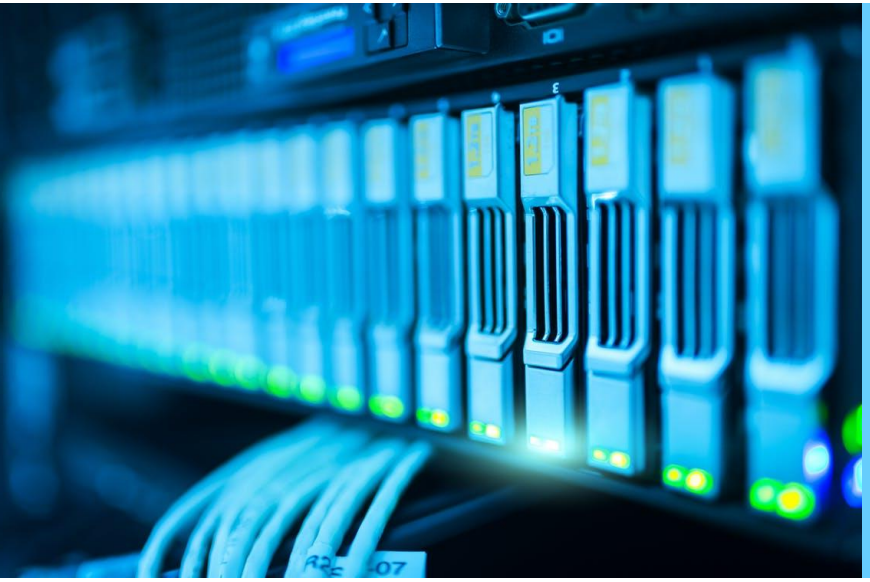
Considerações Finais

- Comparação entre as técnicas utilizadas
- Validação dos resultados
- Escolha da técnica mais adequada

@2020 FIA LABDATA. Copyright all rights reserved.

6. Modelagem Estatística Tradicional

BALANCEAMENTO | BASES DE TREINO E TESTE



Base de dados para modelagem

1. 70% aleatório para treino e 30% para teste

2. Utilizado somente as variáveis relevantes

3. Separação em treino e teste
   - Treino: 3.223 ocorrências
   - Teste: 1.382 ocorrências

@2020 FIA LABDATA. Copyright all rights reserved.

6. Regressão Logística

MODELAGEM COM ESTATÍSTICA TRADICIONAL | INTERPRETAÇÃO DAS VARIÁVEIS

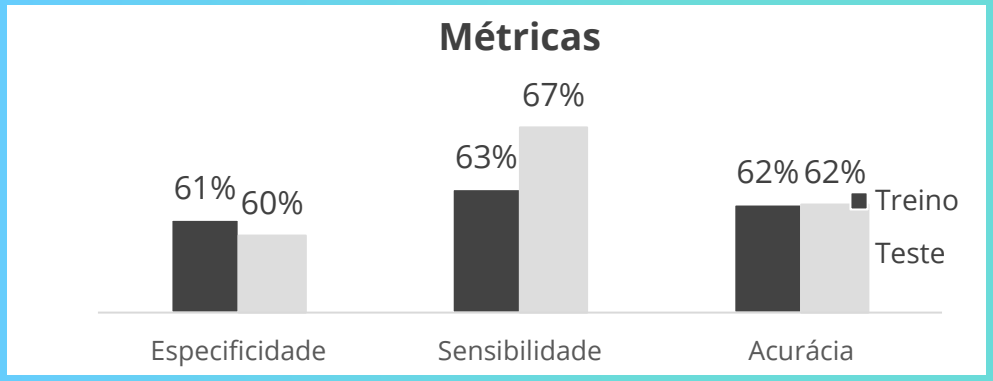
O modelo seleciona as variáveis mais relevantes e estima um peso para cada uma de suas categorias, atribuindo para cada ocorrência a probabilidade de ocorrer feridos graves ou mortos..

$$p = \frac{e^{\beta_0+\beta_1X_1+\beta_2X_2+\beta_3X_3+\beta_4X_4}}{1+e^{\beta_0+\beta_1X_1+\beta_2X_2+\beta_3X_3+\beta_4X_4}}$$

Variável	Categoria	Coeficiente (β)	Interpretação em relação a ocorrência Target
Intercepto	-	-0,032	-
Pessoas	-	0,037	Quanto mais pessoas envolvidas no acidente tendem levemente a maior propensão
Veículos	-	0,210	Quanto mais veículos envolvidos no acidente tendem consideravelmente a maior propensão
Causa acidente agg	Veicular	-0,629	Causa do acidente Veicular tem menor propensão, seguido de Via/Natureza e sendo o mais propenso o de Fator Humano
	Via/ Natureza	-0,168	
Tipo pista	Múltipla	0,006	Tipo pista Simples é o mais propenso seguido de Múltipla . E a pista Dupla é o menos propenso
	Simples	0,713	
Tipo acidente categ	Capotamento	-2,085	Atropelamento é o mais propensão, já os demais são menos propensos, principalmente Engavetamento e Capotamento
	Colisão	-1,731	
	Engavetamento	-3,085	
	Outros	-1,914	
	Saída de leito carroçável	-1,913	
	Tombamento	-1,304	

@2020 FIA LABDATA. Copyright all rights reserved.

6. Modelagem Estatística Tradicional - Desempenho dos modelos



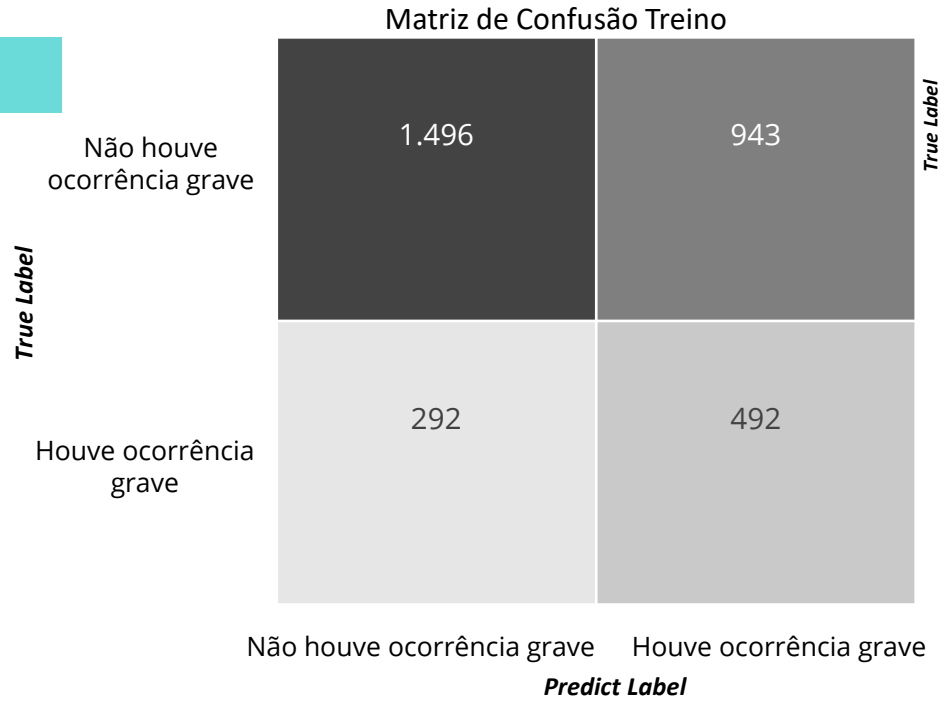
- A **Regressão Logística** apresentou **acerto** preditivo **satisfatório**, com acerto de **acurácia** (acerto geral) de 62% e **sensibilidade** (acerto do target 1) de 63% e a **especificidade** (acerto do target 0) de 61%.
- Além disso, apresentou o KS de 24,1% aceitável e AUC de 67,1% bom.
- Foi utilizado como ponto de corte o **método do cutpoint** que maximiza a sensibilidade e especificidade.

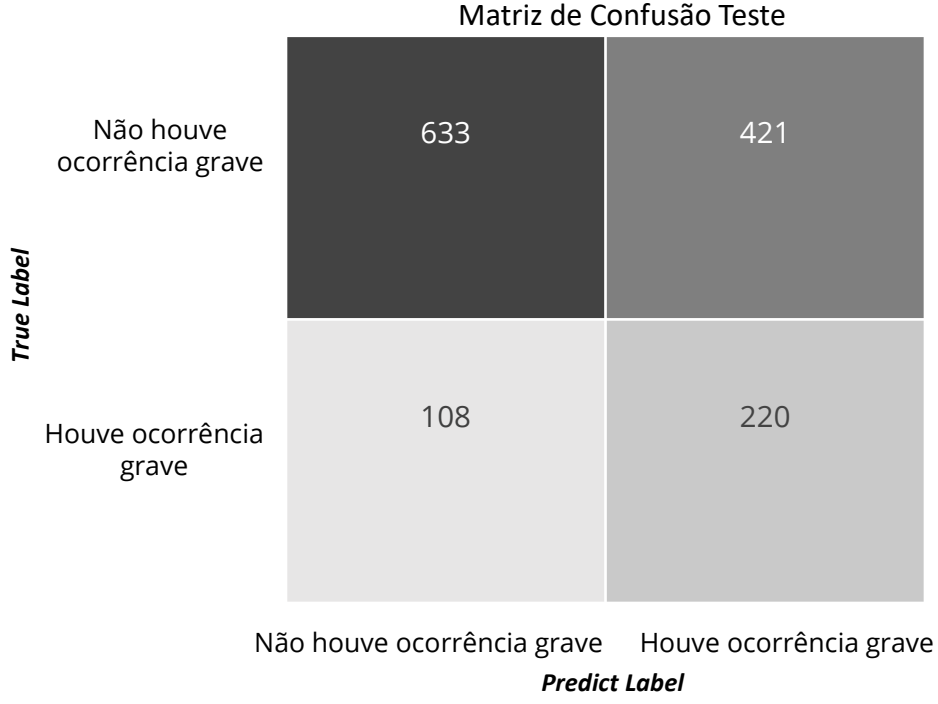
Detalhes do desempenho: Treino x Teste

@2020 FIA LABDATA. Copyright all rights reserved.

6. Modelagem Estatística Tradicional - Desempenho dos modelos

Regressão Logística – ET
Modelo 1 (Ponto de corte 22%)





Para realizar o custo operacional por exemplo na base teste, foi considerado as seguintes premissas:
Custo médio gasto com acidente de trânsito na rodovia é de **R$2.600 por ocorrência**, em casos de ocorrências que não foram prevista o **custo de reparo** é mais alto sendo de **R$3000 por ocorrência** e **o custo de prevenção**, ou seja, no do acidente previsto que não ocorreu é de **R$400 por ocorrência**

Caso o modelo tivesse em produção**, teria um custo de R$1.064.400**, sem a aplicação do modelo o custo seria de **R$852.800**, ou seja com o modelo tem um **acréscimo de R$211.600 no custo** devido ao volume mais alto em **falso positivo**, porém como se trata de uma situação delicada onde envolve vítimas que podem ser ou não fatais, optamos por dar mais aderência a assertividade da **sensibilidade,** considerando que esse acréscimo possa ser revertido em investimento.

Detalhes do desempenho: Custo Operacional

@2020 FIA LABDATA. Copyright all rights reserved.

Metodologia de análise de dados

Planejamento → Análise Exploratória → Modelagem Estatística → **Algoritmos de Inteligência Artificial** → Conclusões

Definição do problema

- Objetivos do Trabalho
- Contextualização do Problema
- Base de dados
- Principais Variáveis

Análise preliminar

- Medidas resumo
- Análise de *outliers*
- Análise de *missings*
- Tratamento dos dados
- Validação com a área de negócios sobre a consistência das informações

Ajuste e Avaliação Modelo

- Regressão Logística

Ajuste e Avaliação dos Modelos

- **Machine Learning:**
  - Regressão Logística
  - Cat Boost
  - XGBoost
- **Deep Learning:**
  - Redes Densas
  - CNN
  - LSTM

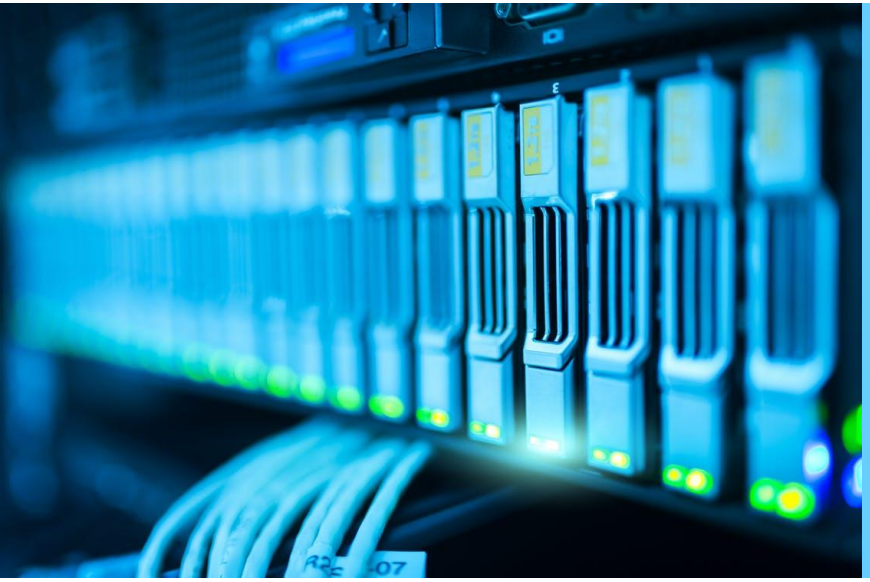
Considerações Finais

- Comparação entre as técnicas utilizadas
- Validação dos resultados
- Escolha da técnica mais adequada

@2020 FIA LABDATA. Copyright all rights reserved.

7.i. Modelagem Algoritmos de Inteligência Artificial – Machine Learning

BALANCEAMENTO | BASES DE TREINO E TESTE



Base de dados para modelagem

1. 70% para treino e 30% para teste, aplicando o stratify = y para manter a distribuição da variável target e o random_state = 42 para garantir a reprodutibilidade

2. Foi utilizado as mesmas variáveis relevantes da Estatística Tradicional

3. Separação em treino e teste
   - Treino: 3.223 ocorrências
   - Teste: 1.382 ocorrências

@2020 FIA LABDATA. Copyright all rights reserved.

7.i. Modelagem Algoritmos de Inteligência Artificial – Validação Cruzada

Machine Learning

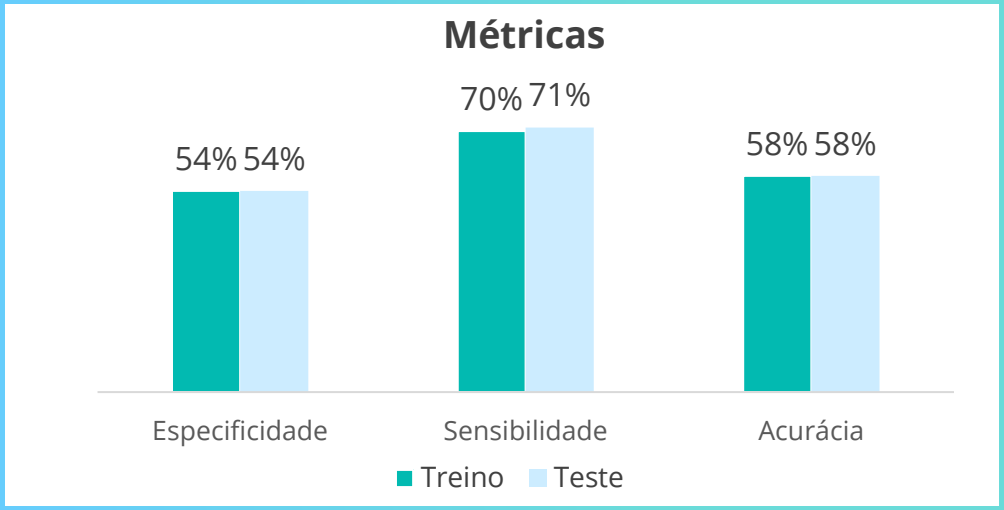
Foi realizado o processo de validação cruzada com 5 folds para os algoritmos Decision Tree, Random Forest, XGB, LightGBM, CatBoost e Regressão Logística , sem nenhuma otimização de hiperparâmetros, apenas com os valores pré-definidos e com ajuste no ponto de corte para maximizar a sensibilidade e manter o mínimo aceitável de especificidade e sensibilidade

Modelo	Ponto de Corte	Acurácia	Precisão	Sensibilidade	Especificidade	F1 Score	Roc AUC
Regressão logística	0.25	0.70	0.40	0.50	0.76	0.44	0.68
Catboost	0.27	0.69	0.39	0.48	0.76	0.43	0.66
XGBoost	0.18	0.52	0.30	0.77	0.44	0.43	0.65
LGBM	0.17	0.51	0.30	0.76	0.43	0.43	0.65
Random_Forest	0.18	0.53	0.30	0.73	0.46	0.43	0.64
DT	0.19	0.52	0.30	0.71	0.47	0.42	0.63

@2020 FIA LABDATA. Copyright all rights reserved.

7.i. Modelagem Algoritmos de Inteligência Artificial – Desempenho do Modelo

Machine Learning



Dos 5 Modelos aplicados , o que obteve um melhor desempenho e mais equilibrado foi o **Modelo 3 (Regressão Logística)** Com o ajuste no ponto de corte e aplicação do Randomized para selecionar os melhores Hiperparametros obteve uma significância mais expressiva no Target 1 com a Sensibilidade de 70%, além disso manteve um equilíbrio em treino e teste e um AUC de 68%.

Além disso com relação a Regressão logística Tradicional, tivemos um aumento de aproximadamente **7p.p treino e 4p.p em teste**.

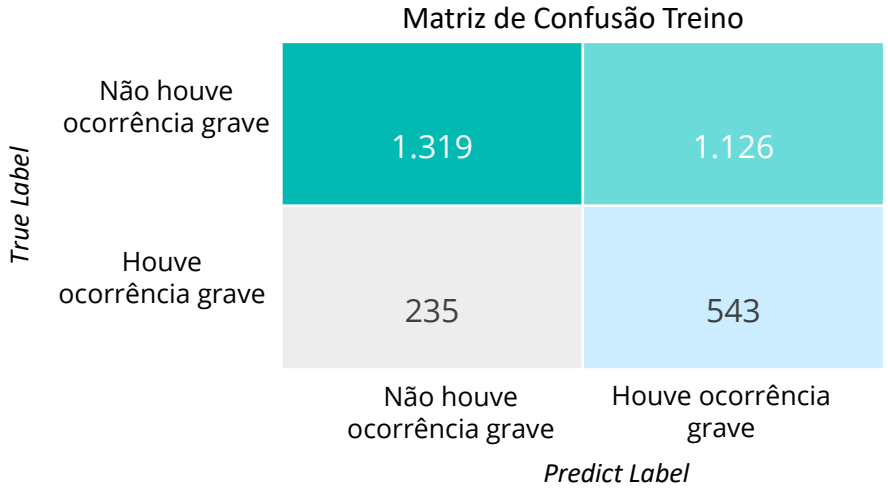
Detalhes das análises dos demais modelos

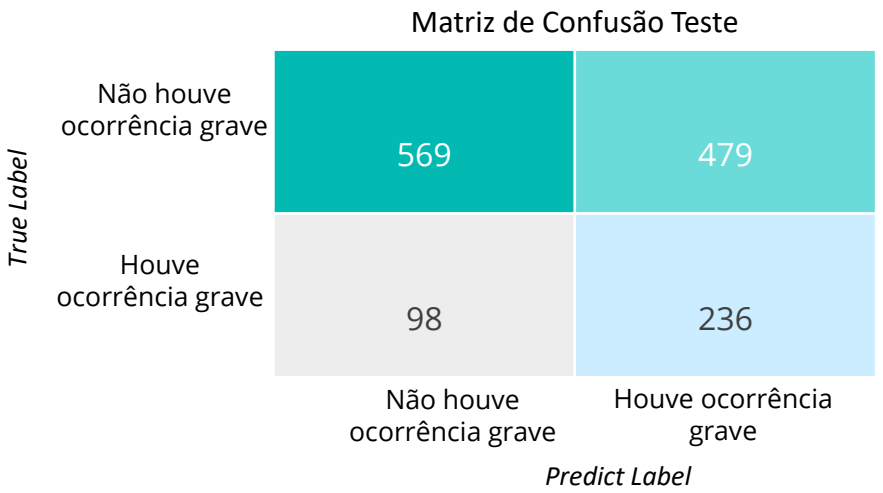
@2020 FIA LABDATA. Copyright all rights reserved.

7.i. Modelagem Algoritmos de Inteligência Artificial – Desempenho do Modelo

Machine Learning

Regressão Logística – ML
Modelo 3 (Ponto de corte 47%)





Para realizar o custo operacional por exemplo na base teste, foi considerado as seguintes premissas:
Custo médio gasto com acidente de trânsito na rodovia é de **R$2.600 por ocorrência**, em casos de ocorrências que não foram prevista o **custo de reparo** é mais alto sendo de **R$3000 por ocorrência** e **o custo de prevenção**, ou seja, no do acidente previsto que não ocorreu é de **R$400 por ocorrência**

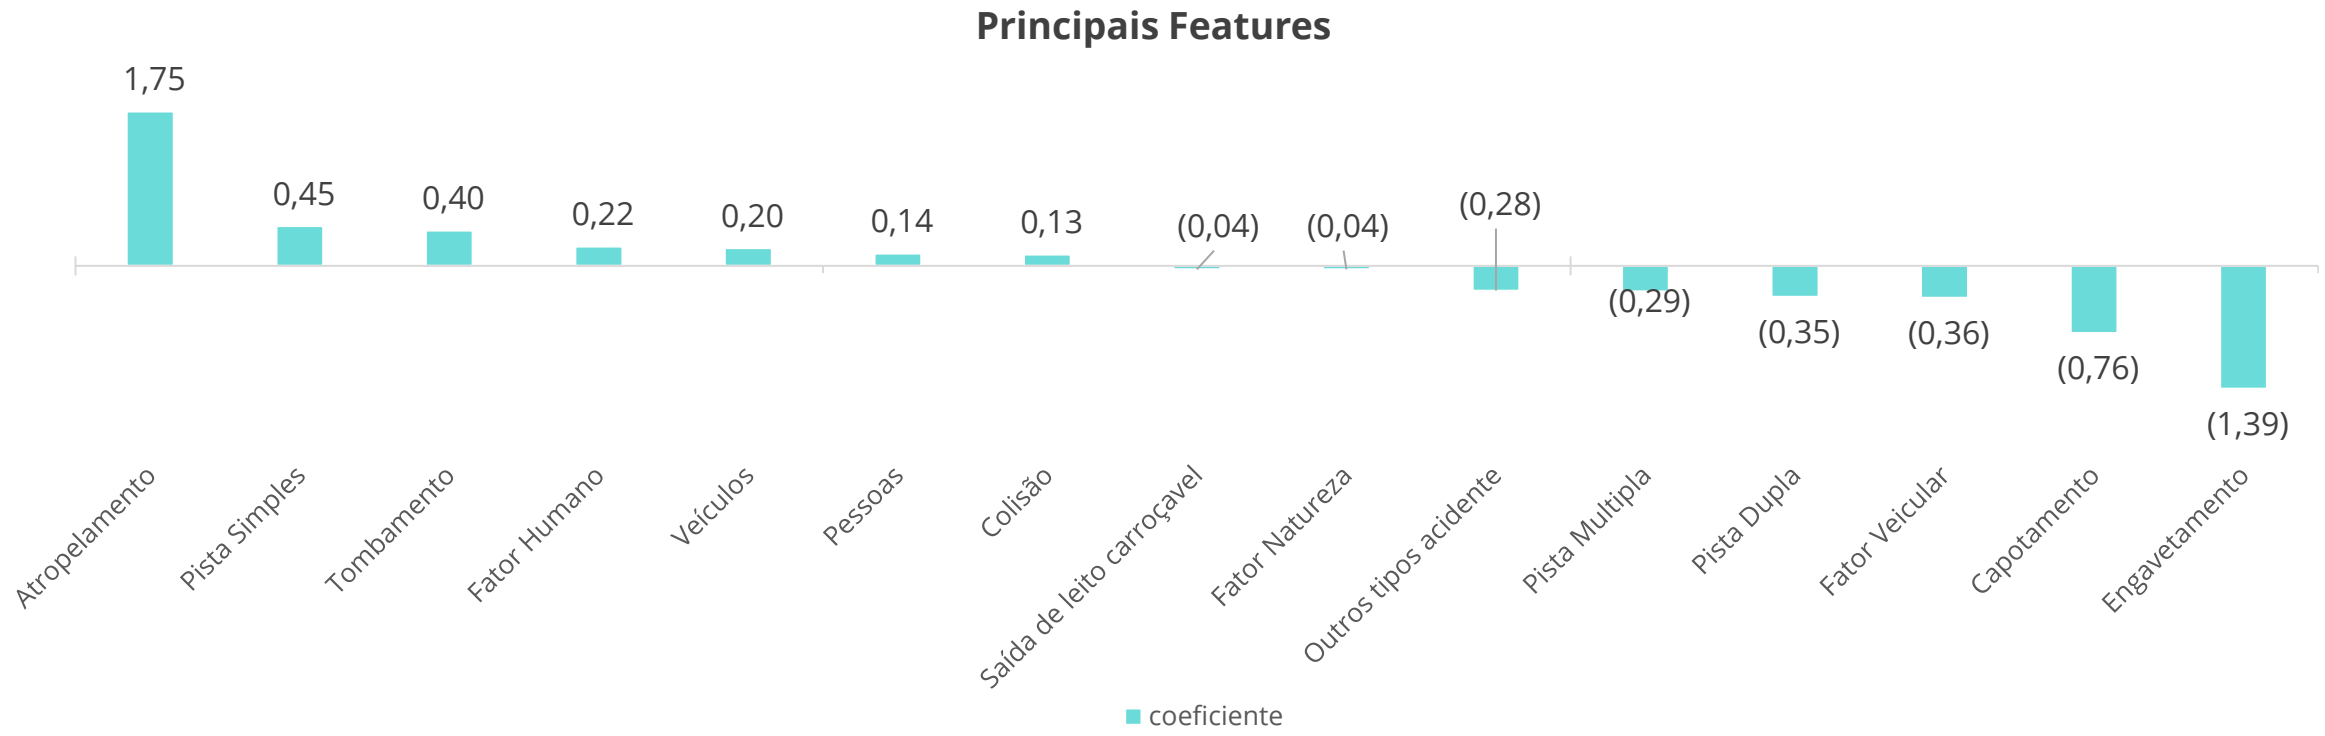
Caso o modelo tivesse em produção**, teria um custo de R$1.099.200**, sem a aplicação do modelo o custo seria de **R$868.400**, ou seja com o modelo tem um **acréscimo de R$230.800 no custo** devido ao volume mais alto em **falso positivo**, porém como se trata de uma situação delicada onde envolve vítimas que podem ser ou não fatais, optamos por dar mais aderência a assertividade da **sensibilidade,** considerando que esse acréscimo possa ser revertido em investimento.
Comparado com a **Estatística Tradicional**, teve um acréscimo **de R$19.200 no custo**, sendo um pouco mais alto.

Detalhes do desempenho: Custo Operacional

@2020 FIA LABDATA. Copyright all rights reserved.

7.i. Modelagem Algoritmos de Inteligência Artificial – Principais Features e Parâmetros

Machine Learning

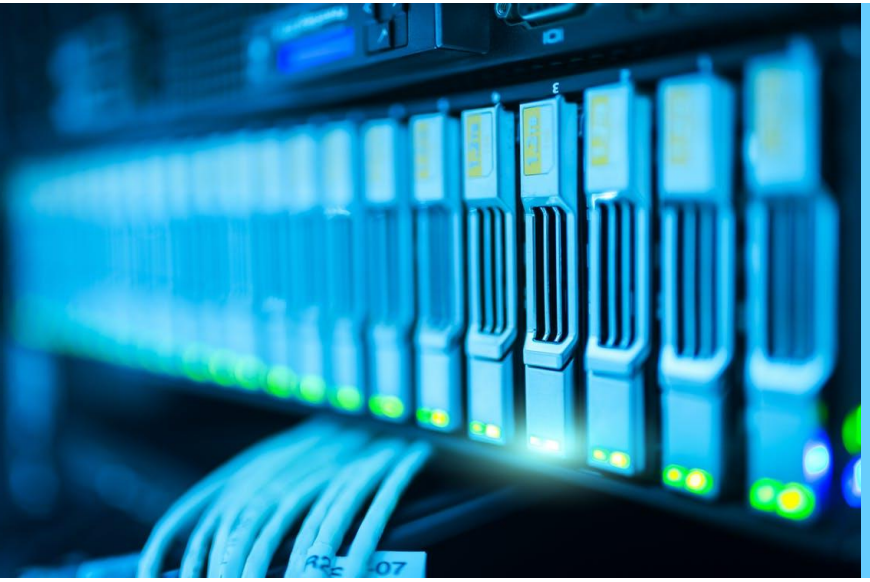


Do **total de 15 features** que o modelo utilizou, vale destacar **Atropelamento** com o coeficiente de **1,75**, isso sugere que este tipo de acidente **aumenta** bastante a probabilidade de um **acidente com feridos grave ou fatal**, seguido de **pista simples com 0,45**. Em **contrapartida Engavetamento com -1,39** seguido de **Capotamento com -0,76** sugere que estão associados a uma **menor** probabilidade de acidentes com **feridos fatais/graves** no conjunto de dados.

Melhores Parâmetros: 'logit__penalty': 'l2', 'logit__fit_intercept': True, 'logit__class_weight': 'balanced', 'logit__C': 100}

@2020 FIA LABDATA. Copyright all rights reserved.

7.ii. Modelagem Algoritmos de Inteligência Artificial – Deep Learning



Base de dados para modelagem

1. 70% para treino e 30% para teste, aplicando o stratify = y para manter a distribuição da variável target e o random_state = 42 para garantir a reprodutibilidade

2. Foi utilizado todas as variáveis

3. Separação em treino e teste
   - Treino: 3.223 ocorrências
   - Teste: 1.382 ocorrências

@2020 FIA LABDATA. Copyright all rights reserved.

7.ii. Modelagem Algoritmos de Inteligência Artificial – Deep Learning

Deep Learning

Foram realizados testes com diferentes algoritmos de Deep Learning para classificação: Redes Densas, Redes Convolucionais e LSTM.
As arquiteturas utilizadas podem ser visualizadas nos anexos.

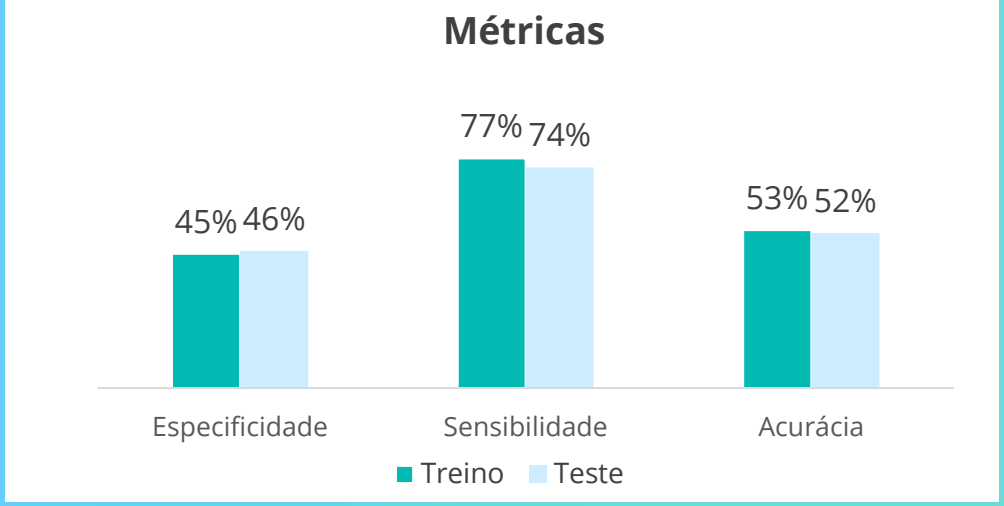
Modelo	Ponto de Corte	Acurácia	Sensibilidade	Especificidade	Roc AUC	Épocas	Batch Size
Densa	0.50	0.86	0.61	0.95	0.88	20	32
Densa completa	0.22	0.63	0.70	0.61	0.71	50	32
CNN completa	0.22	0.53	0.77	0.45	0.68	50	32
LSTM completa	0.22	0.68	0.64	0.69	0.72	50	64

Detalhes das arquiteturas do modelo

@2020 FIA LABDATA. Copyright all rights reserved.

7.ii. Modelagem Algoritmos de Inteligência Artificial – Desempenho do Modelo

Deep Learning



Dos 4 Modelos aplicados , o que obteve um melhor desempenho e mais equilibrado foi o **Modelo 3 (Redes CNN)** Com o ajuste no ponto de corte e regularização obteve uma significância mais expressiva no Target 1 com a Sensibilidade de 74%, além disso manteve um equilíbrio em treino e teste e um AUC de 68%.

Embora teve um aumento na sensibilidade tanto comparado a **Estatística Tradicional 14p.p treino e 7.p.p teste** e quanto a **Regressão Logística de ML 7p.p treino e 3p.p teste** é possível perceber **que não manteve um equilíbrio de treino para teste** e sacrificou muito a especificidade.

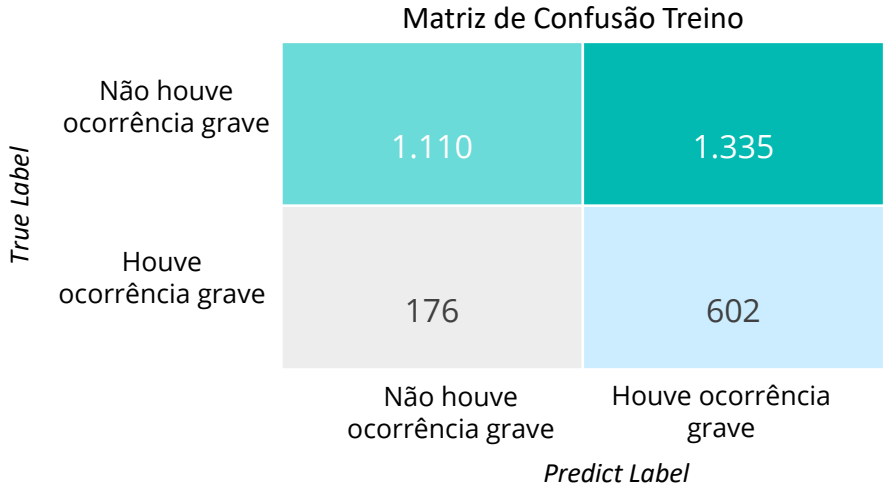
Detalhes das análises dos demais modelos

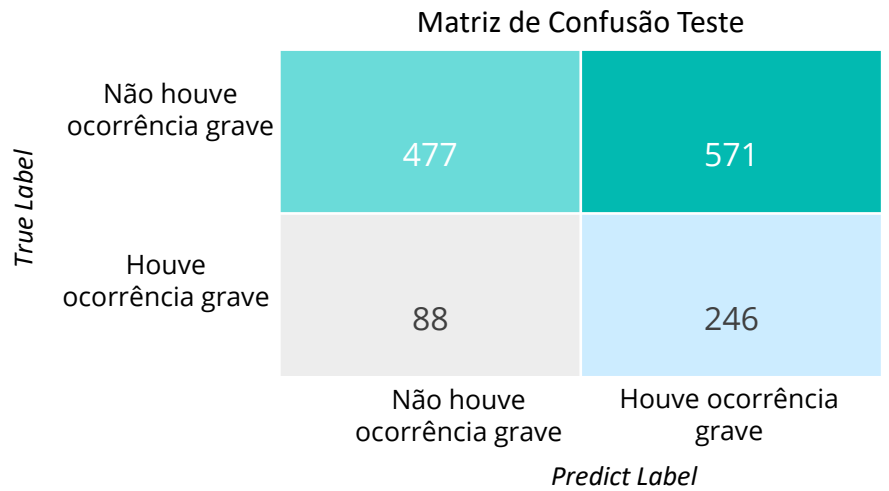
@2020 FIA LABDATA. Copyright all rights reserved.

7.ii. Modelagem Algoritmos de Inteligência Artificial – Desempenho do Modelo

Deep Learning

Redes CNN – DL
Modelo 3 (Ponto de corte 22%)





Para realizar o custo operacional por exemplo na base teste, foi considerado as seguintes premissas:
Custo médio gasto com acidente de trânsito na rodovia é de **R$2.600 por ocorrência**, em casos de ocorrências que não foram prevista o **custo de reparo** é mais alto sendo de **R$3000 por ocorrência** e **o custo de prevenção**, ou seja, no do acidente previsto que não ocorreu é de **R$400 por ocorrência**

Caso o modelo tivesse em produção**, teria um custo de R$1.132.000**, sem a aplicação do modelo o custo seria de **R$868.400**, ou seja com o modelo tem um **acréscimo de R$263.600 no custo** devido ao volume mais alto em **falso positivo**, porém como se trata de uma situação delicada onde envolve vítimas que podem ser ou não fatais, optamos por dar mais aderência a assertividade da **sensibilidade,** considerando que esse acréscimo possa ser revertido em investimento.
Comparado com a **Estatística Tradicional, teve um acréscimo de R$52.000** no custo e comparado a **Regressão Logística ML, teve um acréscimo de R$32.800**, sendo considerado o algoritmo com o custo mais elevado.

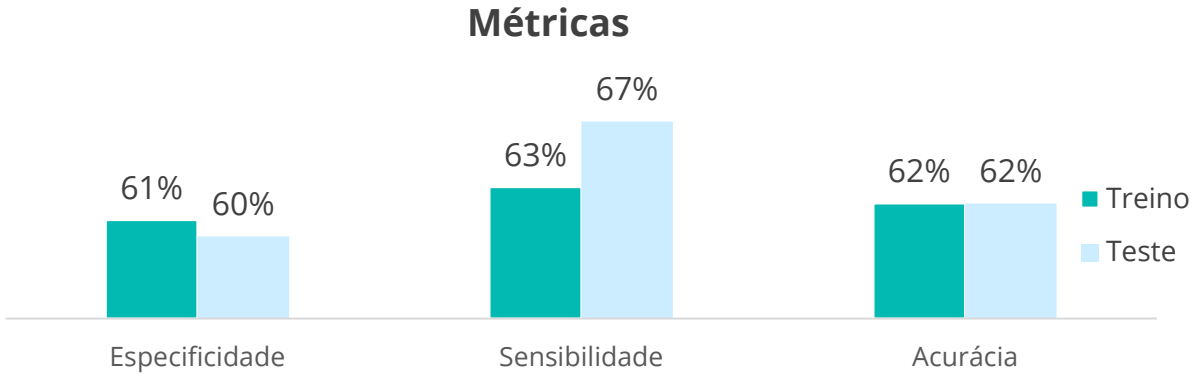
Detalhes do desempenho: Custo Operacional

@2020 FIA LABDATA. Copyright all rights reserved.

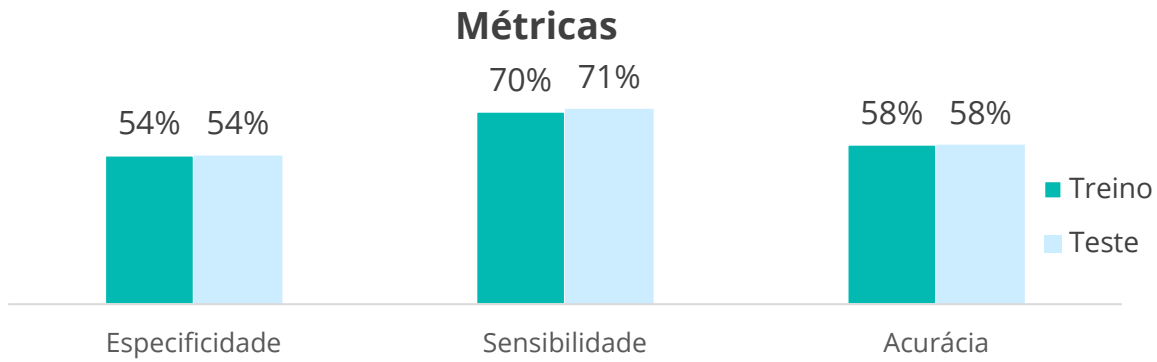
8. Modelagem Algoritmos de Inteligência Artificial – Comparativo

Estatística Tradicional X Machine Learning X Deep Learning

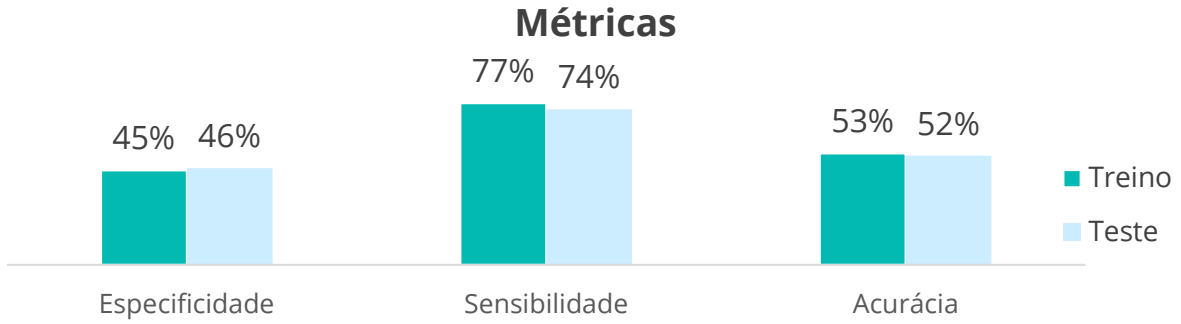
Regressão Logística – ET
Modelo 1 (Ponto de corte 22%)



Regressão Logística – ML
Modelo 3 (Ponto de corte 47%)



Redes CNN – DL
Modelo 3 (Ponto de corte 22%)



Dentre os **3 modelos selecionados** de cada tipo de algoritmo (**Estatística Tradicional, Machine Learning e Deep Learning**, o modelo escolhido foi o **Modelo 3 (Regressão Logística – ML)** pois além de uma boa sensibilidade de **70%, AUC 68%**, manteve um equilíbrio em teste e a especificidade e acurácia estão aceitáveis e embora todos os modelos em seu custo operacional, geram um acréscimo se comparado a performance de custo sem aplicação do modelo, neste caso o valor é de **R$230.800.**

Detalhes do comparativo dos modelos

@2020 FIA LABDATA. Copyright all rights reserved.

Metodologia de análise de dados

Planejamento → Análise Exploratória → Modelagem Estatística → Algoritmos de Inteligência Artificial → Conclusões

Definição do problema

- Objetivos do Trabalho
- Contextualização do Problema
- Base de dados
- Principais Variáveis

Análise preliminar

- Medidas resumo
- Análise de *outliers*
- Análise de *missings*
- Tratamento dos dados
- Validação com a área de negócios sobre a consistência das informações

Ajuste e Avaliação Modelo

- Regressão Logística

Ajuste e Avaliação dos Modelos

- **Machine Learning:**
  - Regressão Logística
  - Cat Boost
  - XGBoost
- **Deep Learning:**
  - Redes Densas
  - CNN
  - LSTM

Considerações Finais

- Comparação entre as técnicas utilizadas
- Validação dos resultados
- Escolha da técnica mais adequada

@2020 FIA LABDATA. Copyright all rights reserved.



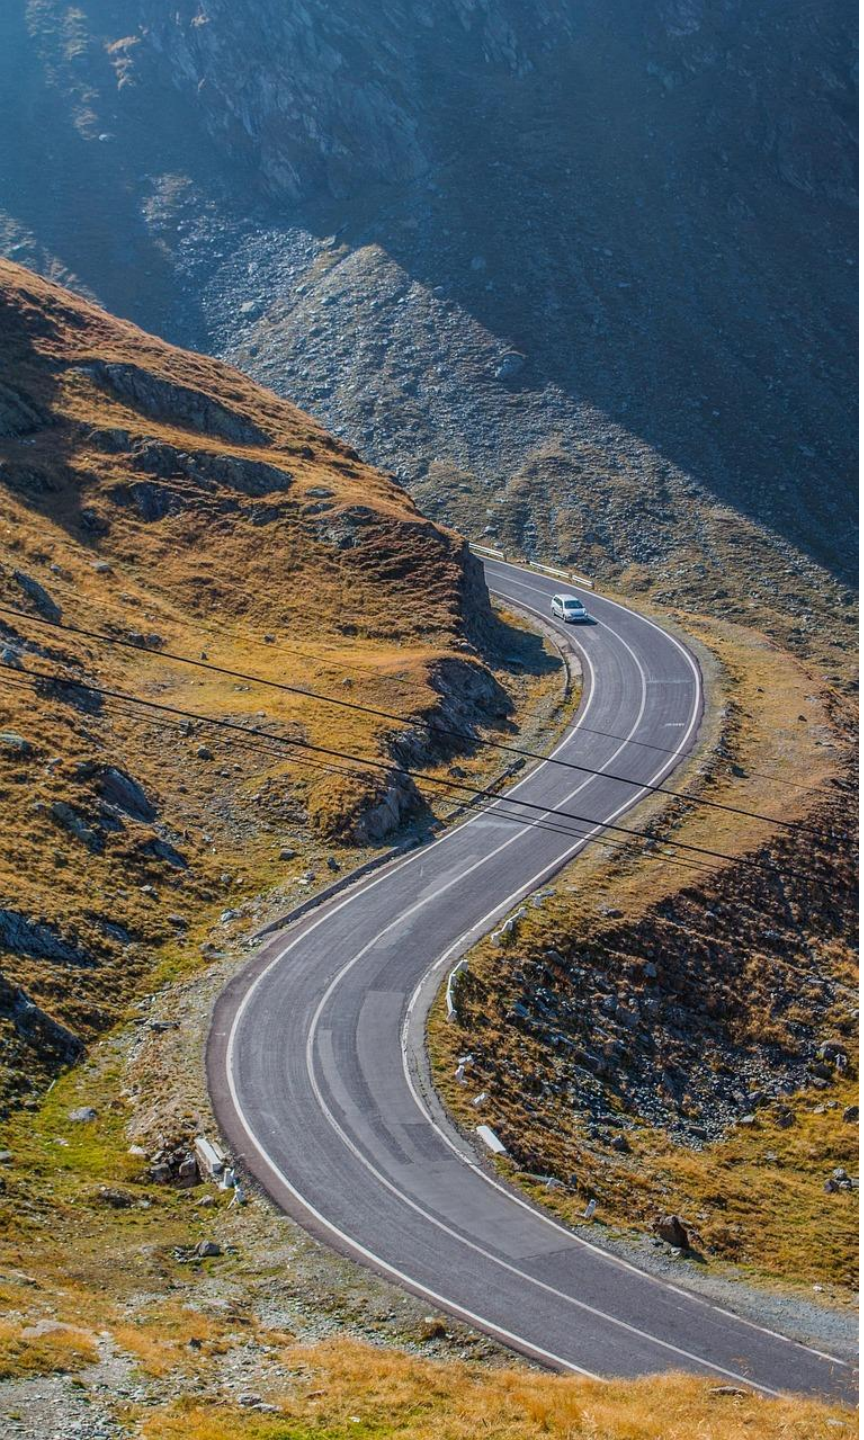
9. Conclusão

- Este projeto foi eficaz em identificar as variáveis relevantes associadas ao acidente com **ocorrências graves (feridos graves ou mortos) em Minas Gerais na BR 381.**
- Foi aplicado desde **modelo tradicional de estatística, até algoritmo de Machine Learning e Deep Learning**. Independente do algoritmo utilizados todos apresentaram um desempenho aceitável, principalmente com relação ao desempenho mais atenuado para Sensibilidade (que é a variável de interesse).
- **A conclusão é de que este trabalho fornece um modelo preditivo** que pode ser usado pela Polícia Rodoviária Federal para acionar equipes de suporte e mobilização de recursos mais eficientes.
- O modelo mais adequado para o problema de negócio foi a **Regressão Logística do Machine Learning** onde foi aplicado ajuste no ponte de corte, selecionado os melhores hiperparâmetros apresentou um **acerto preditivo satisfatório** e mais intensificado para **Sensibilidade com 70% e um AUC de 68%, além de generalizar bem** e ter um resultado similar ao comparar a Base de Treino e Teste, não houve overfting.
- Com relação ao **custo** vale ressaltar que devido o problema de negócio o **foco é a predição do Target1**, logo o custo gerado pelo **volume mais alto em Falso positivo** é melhor do que o custo gerado pelo **menor numero de Falso negativo**. Se aplicar o **modelo em produção** o **custo será de R$1.099.200** , gerando um **acréscimo de R$230.800 se comparado a performance sem o modelo**.
- **As variáveis** compõem o modelo e explicam a ocorrência com feridos graves ou mortos (lembrando que para as categóricas foi aplicado o One Hot Enconder)

❑ Pessoas
❑ Veículos
❑ Causa acidente agg
❑ Tipo pista
❑ Tipo acidente categ

* As variáveis excluídas do teste do modelo foram devido à alta granularidade ou por não ter um IV relevante ou por não ser significativa no modelo.

FIA BUSINESS SCHOOL lab.data



10. Trabalho Futuro

O modelo ainda apresenta oportunidade de melhora visto que embora a Sensibilidade esteja satisfatória o Precision está baixo, indicando um volume alto de Falso Positivo.
Oportunidades futuras a se considerar para aplicar no modelo são:

- **Exploração de Novas features:** Features de novas fontes de dados (perfil da vitíma), dados mais detalhados de condição meteorológica como bases de clima tempo.
- **Abordagem de ténicas de balanceamento:** SMOTE
- **Aplicação de outras otimizações de Hiper parâmetros:** para melhor ajuste do trade off de Sensibilidade e Especificidade

FIA BUSINESS SCHOOL lab.data

- Análises Complementares -

@2020 FIA LABDATA. Copyright all rights reserved.

4.iii. Dicionário de Dados

Dicionário da base original, lembrando que nem todas as variáveis estão sendo utilizadas no modelo.

Nome da Variável	Descrição
ID	Variável com valores numéricos, representando o identificador do acidente.
DATA_INVERSA	Data da ocorrência no formato dd/mm/aaaa.
DIA_SEMANA	Dia da semana da ocorrência. Ex: segunda, terça....
HORÁRIO	Horário da ocorrência no formato hh:mm:ss
UF	Unidade da Federação. Ex: MG,PE,DF...
BR	Variável com valores numéricos, representando o identificador da BR do acidente.
KM	Identificação do quilômetro onde ocorreu o acidente, com valor mínimo de 0,1 km e com casa decimal separada por ponto.
MUNICIPIO	Nome do município de ocorrência do acidente.
CAUSA_ACIDENTE	Identificação da causa principal do acidente. São excluídos os acidentes com esta variável igual a “Não”.
TIPO_ACIDENTE	Identificação do tipo de acidente. Ex: Colisão frontal. São excluídos quando houver >= 2 tipos.
CLASSIFICACAO_ACIDENTE	Classificação quanto a gravidade do acidente. Com ou sem vítimas...

@2020 FIA LABDATA. Copyright all rights reserved.

4.iii. Dicionário de Dados

Dicionário da base original, lembrando que nem todas as variáveis estão sendo utilizadas no modelo.

Nome da Variável	Descrição
FASE_DIA	Fase do dia no momento do acidente: Amanhecer, Pleno dia...
SENTIDO_VIA	Sentido da via considerando o ponto de colisão: Crescente, Decrescente.
CONDIÇÃO_METEOROLOGICA	Condição meteorológica no momento do acidente: Céu claro, chuva...
TIPO_PISTA	Tipo da pista considerando a quantidade de faixa: Dupla, simples, múltipla.
TRACADO_VIA	Descrição do traçado da via.
USO_SOLO	Descrição sobre as características do local do acidente: Urbano = Sim, Rural = Não.
PESSOAS	Total de pessoas envolvidas na ocorrência.
MORTOS	Total de pessoas mortas envolvidas na ocorrência.
FERIDOS_LEVES	Total de pessoas com ferimentos leves envolvidas na ocorrência.
FERIDOS_GRAVES	Total de pessoas com ferimentos graves envolvidas na ocorrência.
FERIDOS	Total de pessoas feridas envolvidas na ocorrência. (soma de feridos_leves e feridos_graves)
ILESOS	Total de pessoas ilesas envolvidas na ocorrência.

@2020 FIA LABDATA. Copyright all rights reserved.

4.iii. Dicionário de Dados

Dicionário da base original, lembrando que nem todas as variáveis estão sendo utilizadas no modelo.

Nome da Variável	Descrição
IGNORADOS	Total de pessoas envolvidas na ocorrência e que não se soube o estado físico.
VEÍCULOS	Total de veículos envolvidos na ocorrência.
ANO_MES_OCORRENCIA	Coluna adicionada. Data da ocorrência no formato aaaa-mm.
MES_OCORRENCIA	Coluna adicionada. Data da ocorrência no formato mm.
REGIAO	Coluna adicionada. Região atribuída a partir da coluna UF.
ZONA	Coluna adicionada. Atribuída a partir da coluna uso_solo, quando Sim = Urbano, Não = Rural.
PERÍODO_DIA	Coluna adicionada. Atribuída a partir da coluna horário. Agrupado em manhã (<=6h), tarde (<=18h), noite (<=23h59), madrugada (a partir da 00 até 5h59).
CAUSA_ACIDENTE_AGG	Coluna adicionada. Agregada a partir da coluna cauda_acidente, categorizado em Fator Humano, Fator Veicular e Fator via/natureza. Fonte de apoio LINK
TIPO_ACIDENTE	Coluna adicionada. Agregada a partir da coluna tipo_acidente . Categorizado em Colisão, Atropelamento, Tombamento, Outros.
HOUVE_MORTE	Coluna adicionada. Houve_morte = 1 refere-se a ocorrências com a coluna mortos > 0 , Houve morte = 0 refere-se a ocorrências com a coluna mortos = 0.

@2020 FIA LABDATA. Copyright all rights reserved.

5.i. Raio-X da base

ANÁLISE EXPLORATÓRIA | UNIVARIADA

Persona geral da base

- Em média ocorrem cerca de **209 ocorrência mensal em MG** referente a **BR 381**
- **75%** das ocorrências envolvem até **3 pessoas** e **2 veículos.**
- A maior parte das ocorrências é causado por **Fator Humano (80%)**
- Sendo o tipo de acidente mais ofensor **Colisão (49%)**
- A condição meteorológica com mais ocorrências é **Céu Claro(59%)**
- E o tipo de pista mais propício mencionado nas ocorrências é **Tipo de pista Dupla (69%)**



@2020 FIA LABDATA. Copyright all rights reserved.

5.i. Raio-X da base

ANÁLISE EXPLORATÓRIA | UNIVARIADA

Variáveis Período

- Ano mês

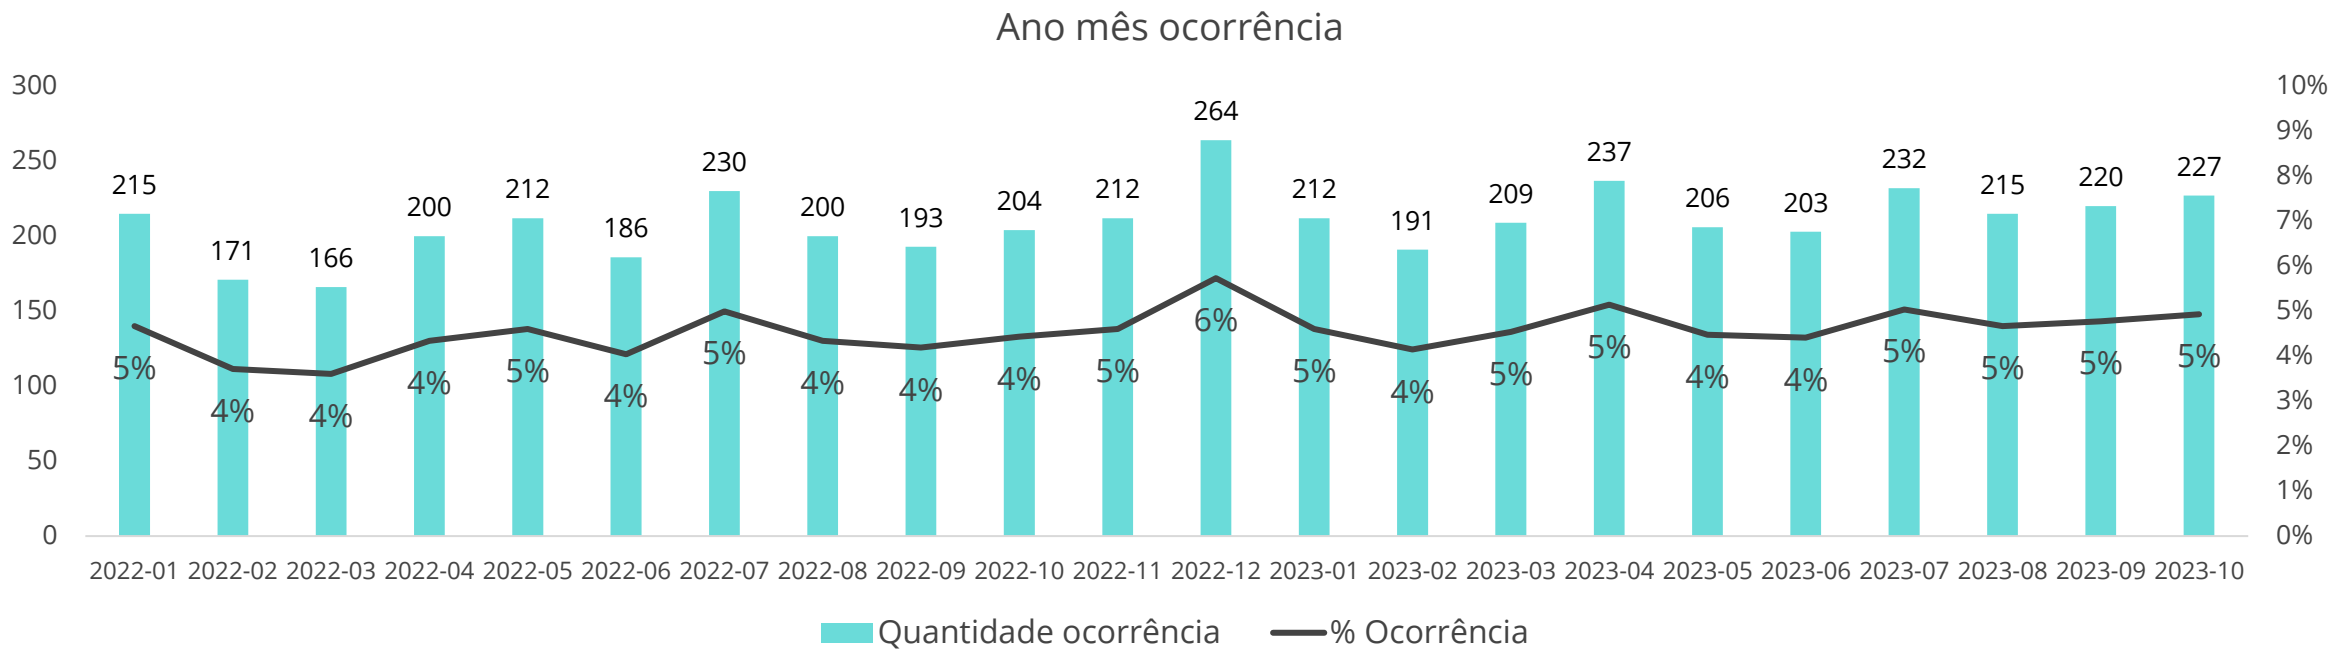
Ano mês ocorrência

Ao longo do período de jan/22 a Out/23, observa-se um comportamento médio de 5%(209) ocorrências mensal. Alguns meses tiveram um pouco acima da média de ocorrências como dez/22 com 264 ocorrências.

@2020 FIA LABDATA. Copyright all rights reserved.

5.i. Detalhes das análises

Variáveis de Período



Ao longo do período histórico de jan/22 a out/23 a média mensal de ocorrências é de 5% (209 ocorrências). Alguns meses como dez/22 esteve bem acima da média.

@2020 FIA LABDATA. Copyright all rights reserved.

5.i. Raio-X da base

ANÁLISE EXPLORATÓRIA | UNIVARIADA



Variável quantitativa

- Veículos
- Pessoas

Quantidade de pessoas

As informações de **quantidade de pessoas**, possuem **distribuições assimétricas acentuadas à direita,** com a presença de **outliers superiores,** porém como sua representatividade (2,6%) na base é baixo, mantive**.**
Sendo 75% das ocorrências com até 3 pessoas envolvidas e um CV de 110,7 (alta variabilidade em torno da média)

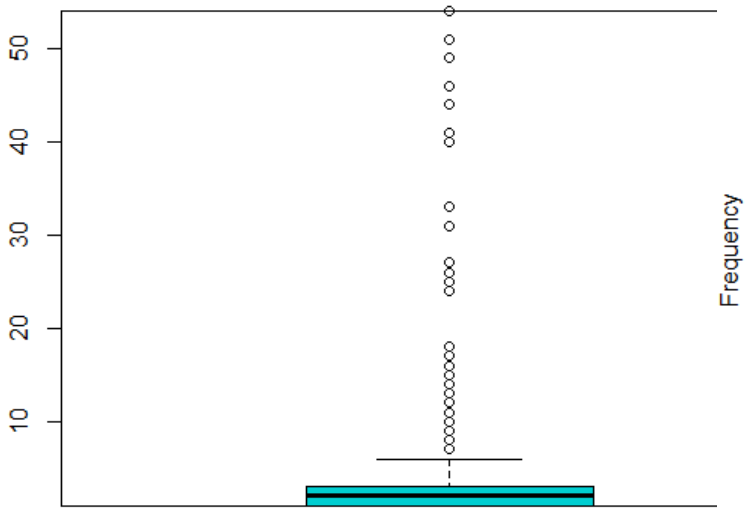
Quantidade de veículos

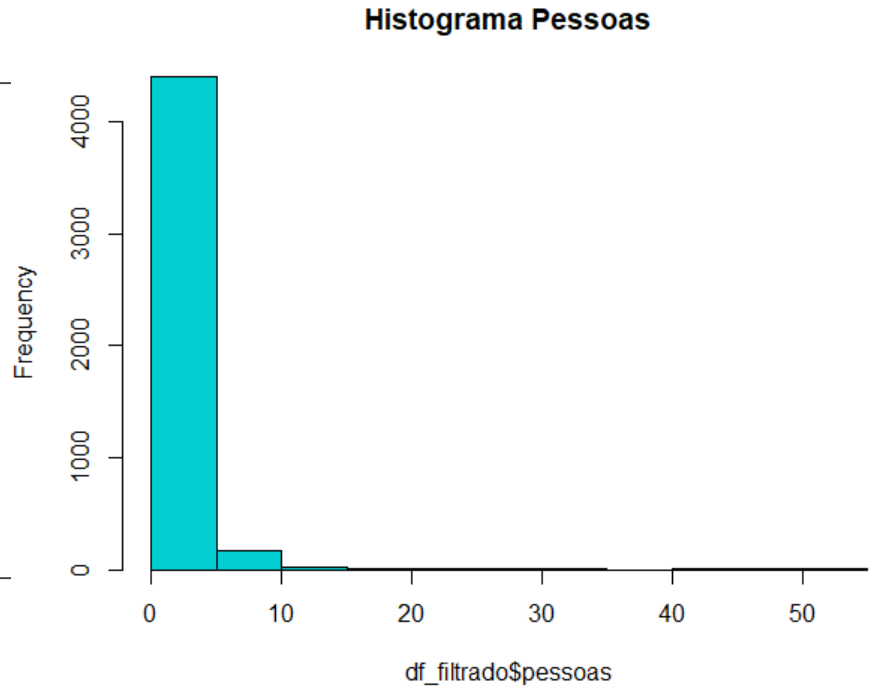
As informações de **quantidade de veículos,** possuem **distribuições assimétricas acentuadas à direita,** com a presença de **outliers superiores.** porém como sua representatividade (2,5%) na base é baixo, mantive
Sendo 75% das ocorrências com até 2 veículos envolvido e um CV de 51,7 (variabilidade considerável em torno da média)

@2020 FIA LABDATA. Copyright all rights reserved.

5.i. Detalhes das análises

Variáveis Quantitativa





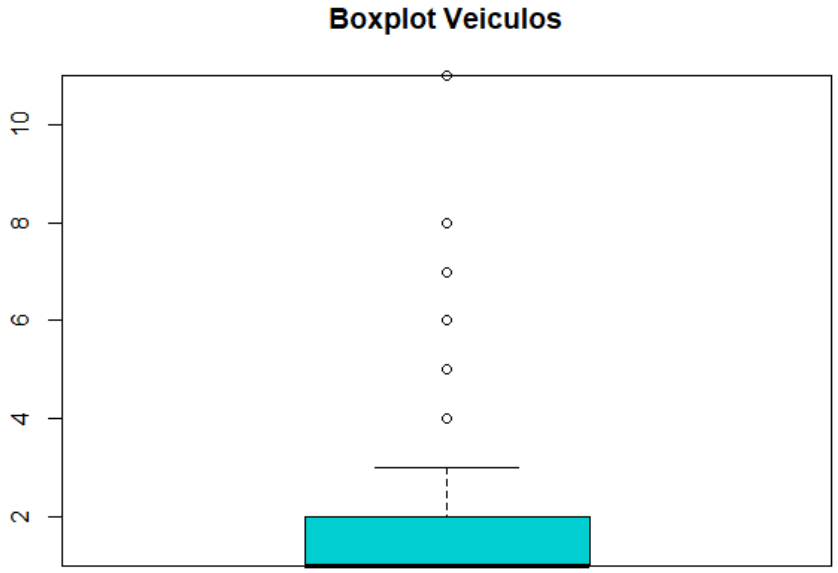
Medida	Valor
Mínimo	1
1º Quartil	1
Mediana	2
Média	2,46
3º Quartil	3
Máximo	54
LS	6
Desvio padrão	2,71
Coeficiente de variação	110,67

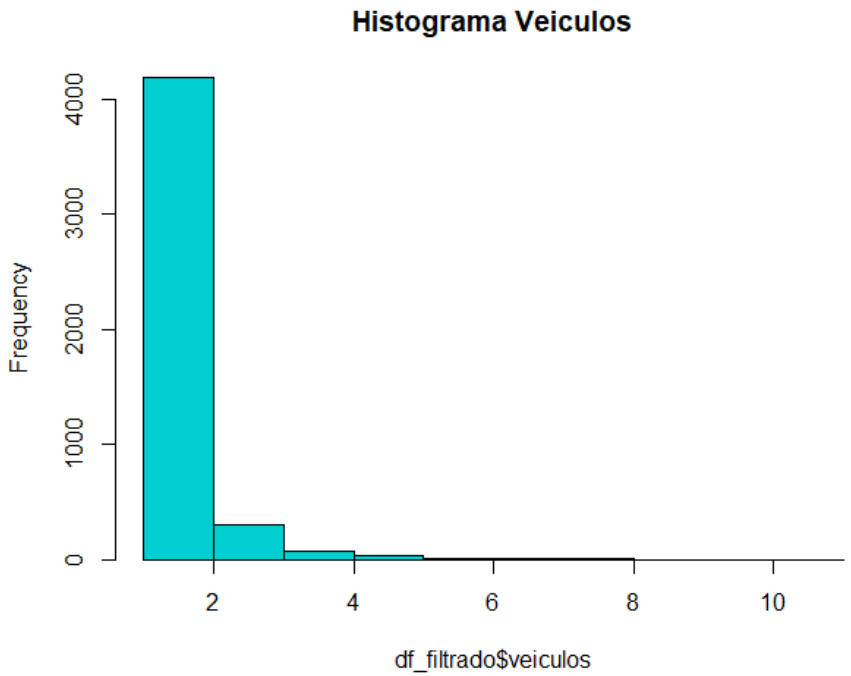
A variável quantidade de pessoas possui distribuição assimétrica acentuada á direita, com a presença de outliers superiores (>6), sendo 50% das ocorrências com até 2 pessoas envolvidas. A média é de 2,46 de pessoas um pouco superior a mediana e o Coeficiente de variação é de 110,67, ou seja há uma alta variabilidade com relação a média.
Como tenho uma quantidade baixa de outlier na base apenas 2,6% (121 ocorrências) e ao tentar aplicar o smbinning não obtive uma melhora na qualidade do modelo, optei em manter os dados na base.

@2020 FIA LABDATA. Copyright all rights reserved.

5.i. Detalhes das análises

Variáveis Quantitativa





Medida	Valor
Mínimo	1
1º Quartil	1
Mediana	1
Média	1,58
3º Quartil	2
Máximo	11
LS	3,5
Desvio padrão	0,81
Coeficiente de variação	51,65

A variável quantidade de veículos possui distribuição assimétrica acentuada á direita, com a presença de outliers superiores (>3,5) , sendo metade das ocorrências com 1 veículo. A média é de 1,58 de veículos um pouco superior a mediana e o Coeficiente de variação é de 51,65, ou seja há variabilidade considerável com relação a média.
Como tenho uma quantidade baixa de outlier na base apenas 2,5% (116 ocorrências) e ao tentar aplicar o smbinning não obtive uma melhora na qualidade do modelo, optei em manter os dados na base.

@2020 FIA LABDATA. Copyright all rights reserved.

5.i. Raio-X da base

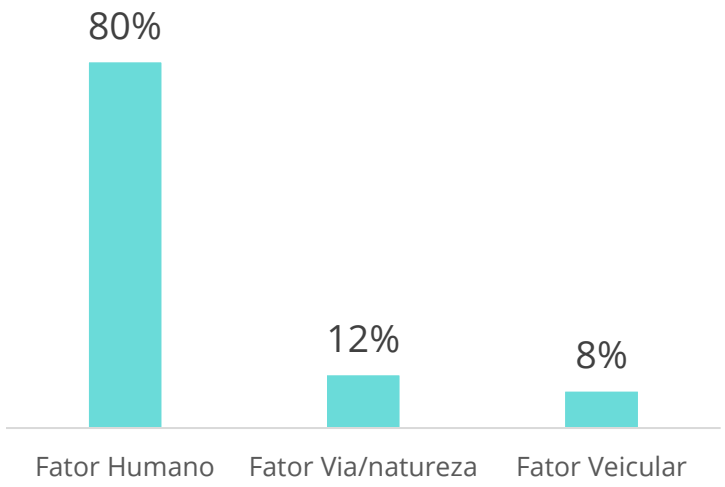
ANÁLISE EXPLORATÓRIA | UNIVARIADA

Variáveis Identificação

- Causa do acidente agg
- Tipo do acidente categ

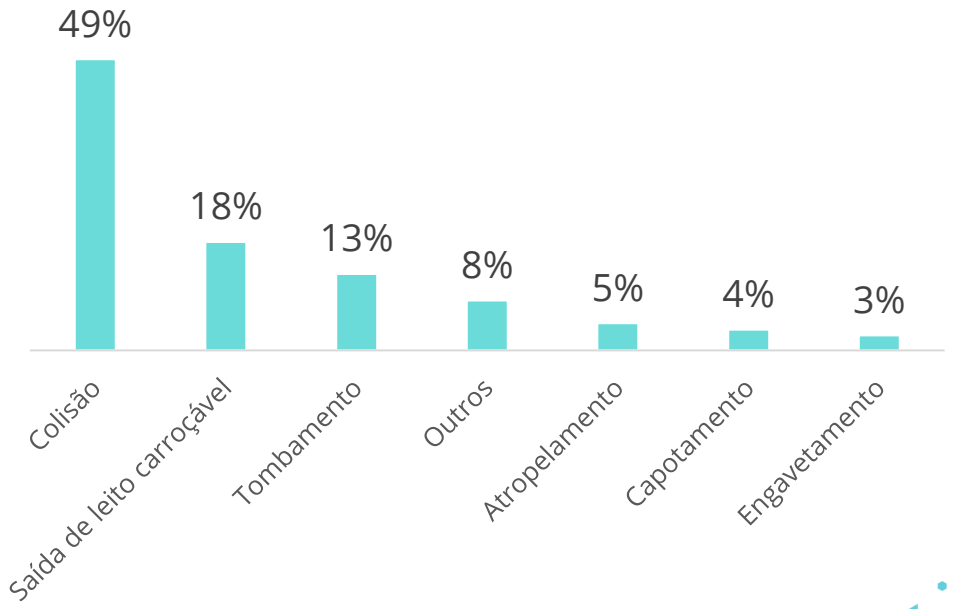
Causa do acidente agg

80% (3.688) das ocorrências são causadas por Fator Humano , dentre essas destaque para **Velocidade Incompatível , Ausência de reação do condutor** que representam um total de1.571 ocorrências.



Tipo do acidente categ

O tipo de acidente Colisão é responsável por 49% (2.276) das ocorrências, podemos destacar **Colisão traseira, Colisão com objeto** que representam um total de 1.397 ocorrências.



@2020 FIA LABDATA. Copyright all rights reserved.

5.i. Detalhes das análises

Variáveis de Identificação

Causa acidente agg	Absoluto	Frequência	Percentual
Fator Humano	3.688	0,80	80%
Fator Via/ Natureza	540	0,12	12%
Fator Veicular	377	0,08	8%
Total	4.605	1,0	100%

Tipo acidente categ	Absoluto	Frequência	Percentual
Colisão	2.276	0,49	49%
Saída de leito carroçável	847	0,18	18%
Tombamento	540	0,12	12%
Outros	391	0,08	8%
Atropelamento	213	0,05	5%
Capotamento	162	0,04	4%
Engavetamento	117	0,03	3%
Total	4.605	1,0	100%

Fator Humano é a causa de acidente mais recorrente com 80% (3.688) em ocorrências, vale destacar que consideramos aqui imprudências humanas , ou seja, fatores que poderiam ser evitados, tanto por parte do condutor, quanto por parte do pedestre.
Já com relação ao tipo de acidente, Colisão e Saída de leito carroçável quando somados, representam + de 60%(3.123) das ocorrências.

@2020 FIA LABDATA. Copyright all rights reserved.

5.i. Detalhes das análises

Variáveis de Identificação

Causa acidente Fator Humano	Qtd ocorrência
Velocidade Incompatível	860
Ausência de reação do condutor	711
Reação tardia ou ineficiente do condutor	515
Condutor Dormindo	247
Manobra de mudança de faixa	245
Condutor deixou de manter distância do veículo da frente	216
Acessar a via sem observar a presença dos outros veículos	151
Ingestão de álcool pelo condutor	144
Transitar na contramão	75
Trafegar com motocicleta (ou similar) entre as faixas	56
Ultrapassagem Indevida	50
Mal súbito do condutor	48
Conversão proibida	47
Entrada inopinada do pedestre	45
Pedestre andava na pista	45
Pedestre cruzava a pista fora da faixa	37

Causa acidente Fator Humano	Qtd ocorrência
Curva acentuada	32
Carga excessiva e/ou mal acondicionada	30
Desrespeitar a preferência no cruzamento	24
Frear bruscamente	24
Transitar no acostamento	22
Estacionar ou parar em local proibido	16
Retorno proibido	13
Ingestão de álcool e/ou substâncias psicoativas pelo pedestre	12
Condutor usando celular	10
Ingestão de substâncias psicoativas pelo condutor	6
Modificação proibida	2
Transtornos Mentais (exceto suicidio)	1
Suicídio (presumido)	1
Participar de racha	1
Transitar na calçada	1
Ingestão de álcool ou de substâncias psicoativas pelo pedestre	1

@2020 FIA LABDATA. Copyright all rights reserved.

5.i. Detalhes das análises

Variáveis de Identificação

Causa acidente Fator Via/Natureza	Qtd ocorrência
Chuva	147
Animais na Pista	46
Pista Escorregadia	42
Acumulo de água sobre o pavimento	40
Objeto estático sobre o leito carroçável	36
Pista esburacada	30
Demais falhas na via	28
Acesso irregular	25
Afundamento ou ondulação no pavimento	22
Acumulo de areia ou detritos sobre o pavimento	14
Acumulo de óleo sobre o pavimento	13
Ausência de sinalização	13
Sinalização mal posicionada	8
Obras na pista	8

Causa acidente Fator Via/Natureza	Qtd ocorrência
Declive acentuado	8
Obstrução na via	7
Demais Fenômenos da natureza	7
Falta de elemento de contenção que evite a saída do leito carroçável	6
Desvio temporário	6
Fumaça	5
Acostamento em desnível	5
Iluminação deficiente	5
Deficiência do Sistema de Iluminação/Sinalização	5
Pista em desnível	5
Falta de acostamento	4
Neblina	4
Área urbana sem a presença de local apropriado para a travessia de pedestres	1

@2020 FIA LABDATA. Copyright all rights reserved.

5.i. Detalhes das análises

Variáveis de Identificação

Causa acidente Fator Veicular	Qtd ocorrência
Demais falhas mecânicas ou elétricas	240
Avarias e/ou desgaste excessivo no pneu	89
Problema com o freio	34
Problema na suspensão	12
Sistema de drenagem ineficiente	2

@2020 FIA LABDATA. Copyright all rights reserved.

5.i. Detalhes das análises

Variáveis de Identificação

Tipo de acidente Atropelamento	Qtd ocorrência
Atropelamento de Pedestre	174
Atropelamento de Animal	39

Tipo de acidente Outros	Qtd ocorrência
Queda de ocupante de veículo	216
Incêndio	132
Eventos atípicos	31
Derramamento de carga	12

Tipo de acidente Engavetamento	Qtd ocorrência
Engavetamento	117

Tipo de acidente Tombamento	Qtd ocorrência
Tombamento	599

Tipo de acidente Colisão	Qtd ocorrência
Colisão traseira	816
Colisão com objeto	581
Colisão lateral mesmo sentido	433
Colisão transversal	198
Colisão frontal	176
Colisão lateral sentido oposto	72

Tipo de acidente Saída de leito carroçável	Qtd ocorrência
Saída de leito carroçável	847

Tipo de acidente Capotamento	Qtd ocorrência
Capotamento	162

@2020 FIA LABDATA. Copyright all rights reserved.

5.i. Raio-X da base

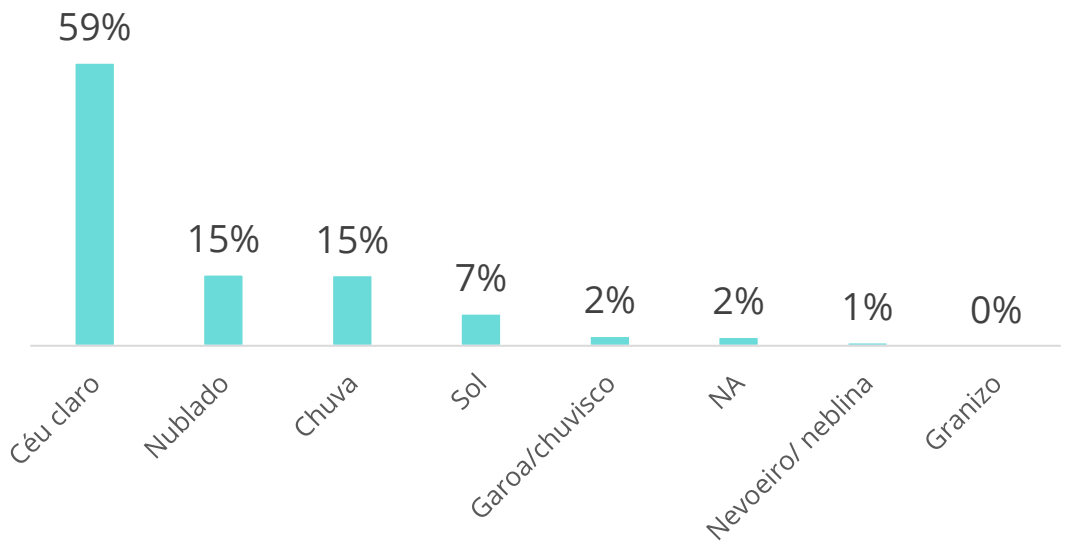
ANÁLISE EXPLORATÓRIA | UNIVARIADA

Variável descritiva

- Condição meteorológica
- Tipo pista

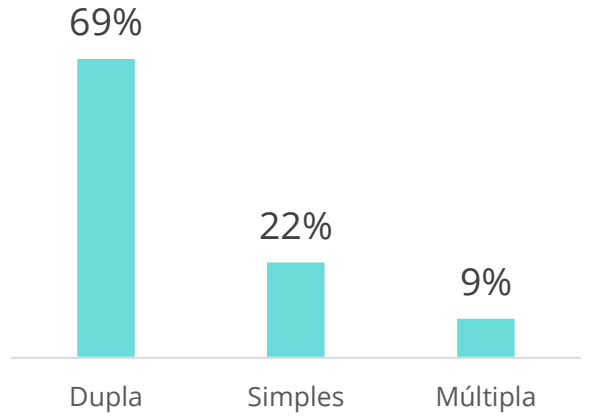
Condição Meteorológica

Das 7 condições meteorológicas, (exceto missing value), Céu Claro representa mais da metade das ocorrências. (2.721) O missing value é de apenas 2% por tal motivo foi mantido na base.



Tipo pista

O tipo de pista Dupla é responsável por 69% das ocorrências e somados ao tipo de pista Simples representam 91% das ocorrências, ou seja, 4.182 ocorrências.



@2020 FIA LABDATA. Copyright all rights reserved.

5.i. Detalhes das análises

Variáveis Descritiva

Condição meteorológica	Absoluto	Frequência	Percentual
Céu Claro	2.721	0,59	59%
Nublado	684	0,15	15%
Chuva	679	0,15	15%
Sol	310	0,07	7%
Garoa/ Chuvisco	94	0,02	2%
NA	85	0,02	2%
Nevoeiro/ Neblina	31	0,01	1%
Granizo	1	0,00	0%
Total	4.605	1,0	100%

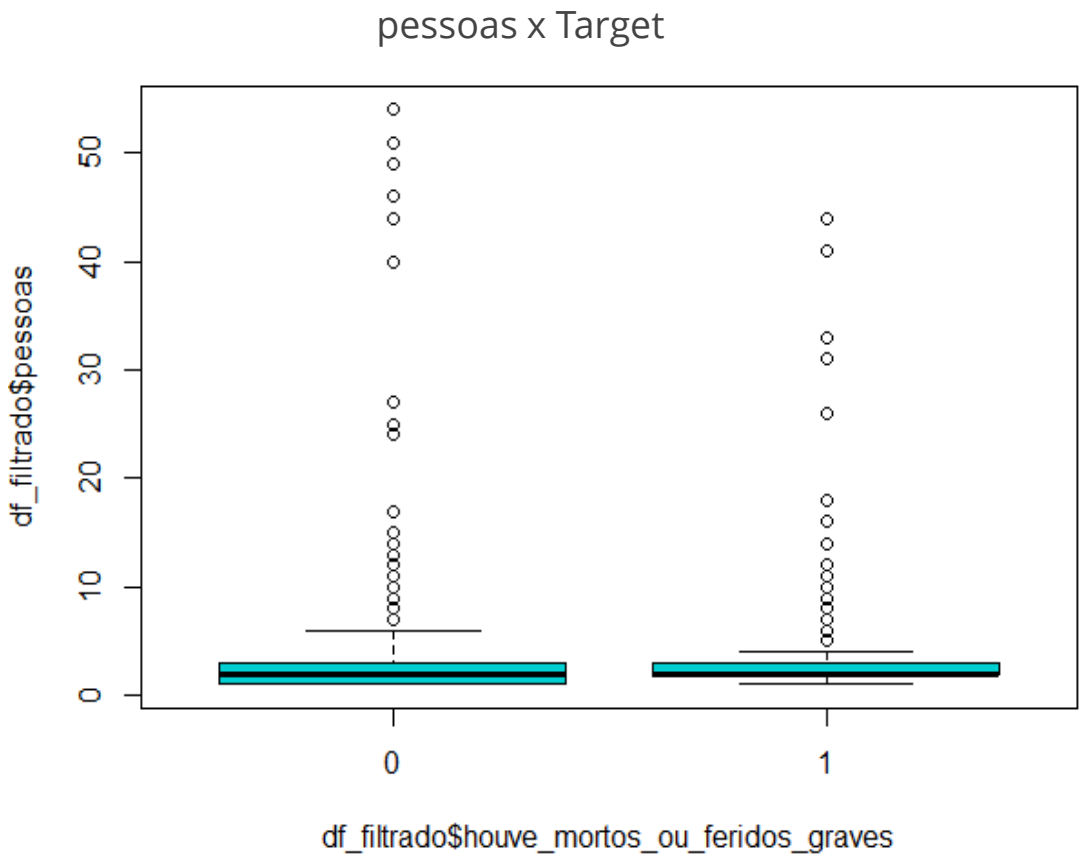
Tipo pista	Absoluto	Frequência	Percentual
Dupla	3.164	0,69	69%
Simples	1.018	0,22	22%
Múltipla	423	0,09	9%
Total	4.605	1,0	100%

A condição meteorológica Céu Claro tem uma representatividade de 59% das ocorrências com 2.721. Com relação ao tipo de pista quando Dupla é 69% (3.164) das ocorrências.

@2020 FIA LABDATA. Copyright all rights reserved.

5.ii. Análise detalhada

ANÁLISE EXPLORATÓRIA | BIVARIADA



Medida	Target = 0	Target = 1
Mínimo	1	1
1º Quartil	1	2
Mediana	2	2
Média	2,37	2,77
3º Quartil	3	3
Máximo	54	44
LS	6	4,5
Desvio padrão	2,68	2,82
Coeficiente de variação	113,08	101,81

LEGENDA

- Covariável parece explicar bem a resposta
- Covariável parece explicar pouco a resposta
- Covariável parece não explicar a resposta

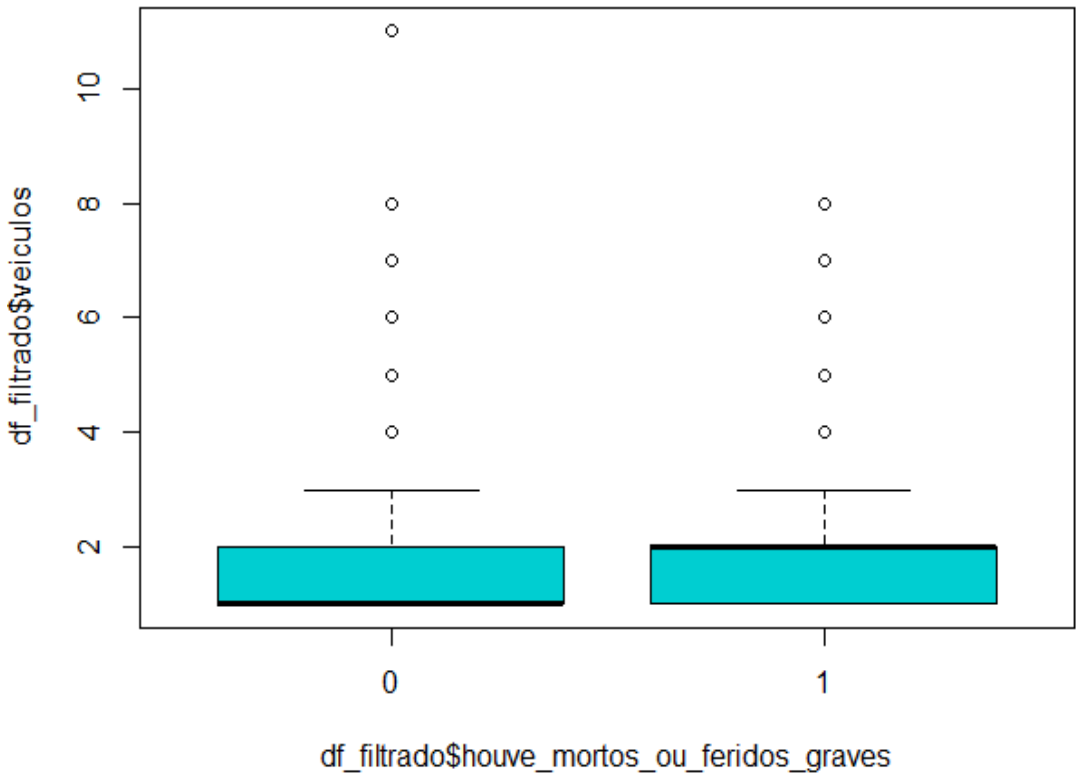
Embora 25%(Q1) da base no target = 1 tem 2 pessoas envolvidas na ocorrência no target = 0 é diferente, somente 1 pessoa. Já com relação a mediana e o Q3 ambos refletem o mesmo comportamento

@2020 FIA LABDATA. Copyright all rights reserved.

5.ii. Análise detalhada

ANÁLISE EXPLORATÓRIA | BIVARIADA

Veículos x Target



Medida	Target = 0	Target = 1
Mínimo	1	1
1º Quartil	1	1
Mediana	1	2
Média	1,54	1,70
3º Quartil	2	2
Máximo	11	8
LS	3,5	3,5
Desvio padrão	0,79	0,87
Coeficiente de variação	51,30	51,17

LEGENDA

Covariável parece explicar bem a resposta

Covariável parece explicar pouco a resposta

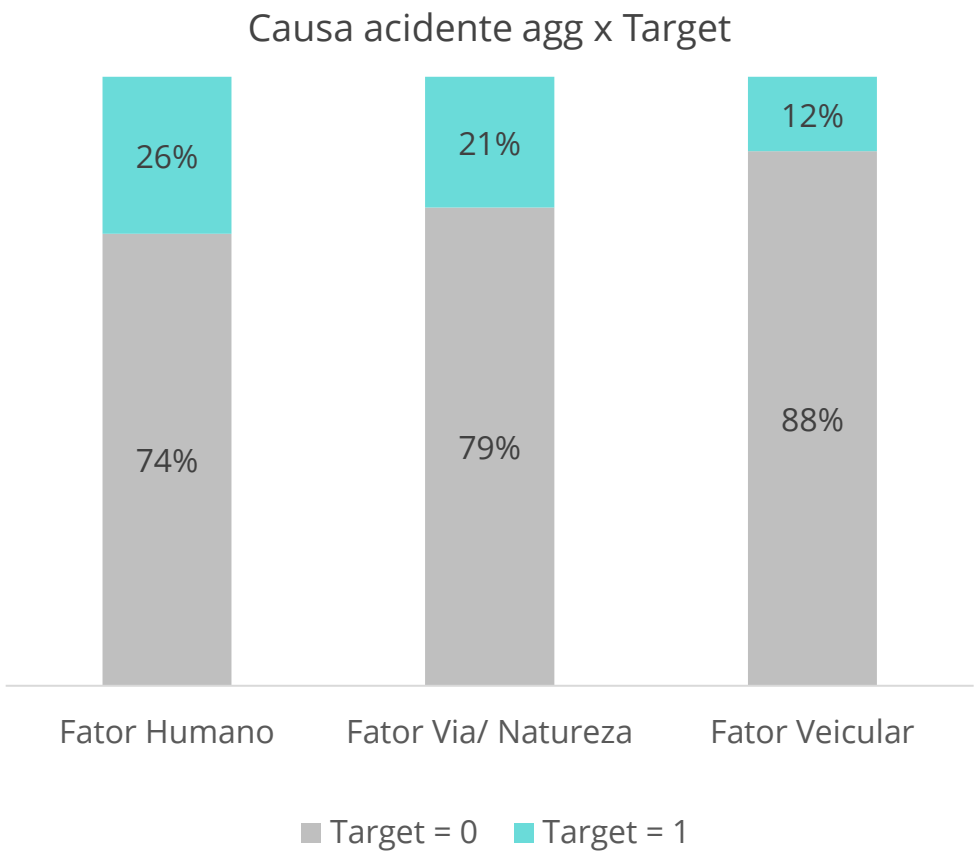
Covariável parece não explicar a resposta

Embora a mediana (50%) da base no target = 1 tem 2 veículos envolvidos na ocorrência, no target = 0 somente 1 veículo esta envolvido. Já com relação a Q1 e Q3 ambos refletem o mesmo comportamento

@2020 FIA LABDATA. Copyright all rights reserved.

5.ii. Análise detalhada

ANÁLISE EXPLORATÓRIA | BIVARIADA



Causa acidente agg	Target = 0	Target = 1
Fator Humano	2.738	950
Fator Via/ Natureza	424	116
Fator Veicular	331	46
Total	3.493	1.112

LEGENDA

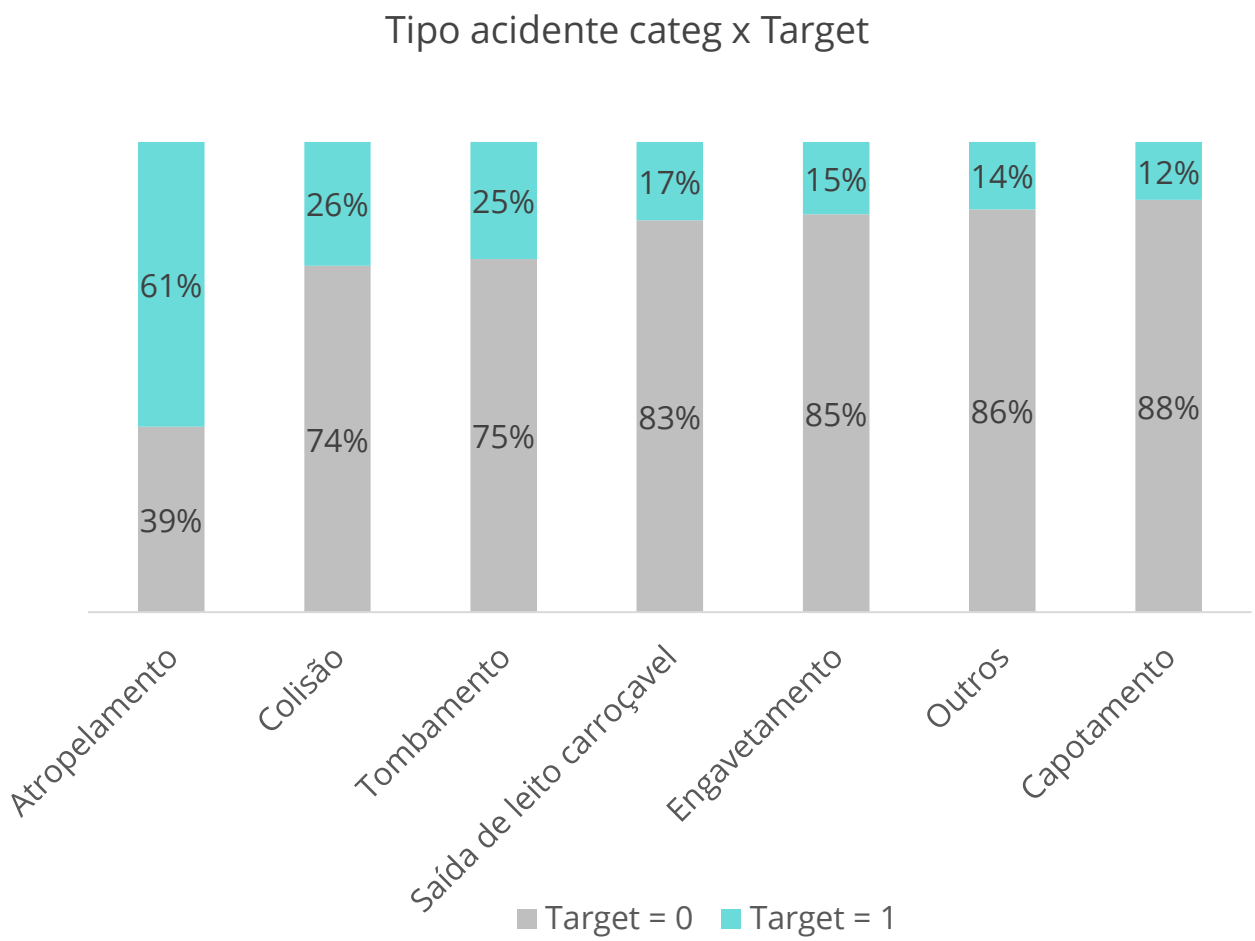
- Covariável parece explicar bem a resposta
- Covariável parece explicar pouco a resposta
- Covariável parece não explicar a resposta

Quando a causa do acidente é Fator Humano ou Via/Natureza tem mais casos de feridos graves ou mortos do que quando ocorre por Fator Veicular

@2020 FIA LABDATA. Copyright all rights reserved.

5.ii. Análise detalhada

ANÁLISE EXPLORATÓRIA | BIVARIADA



Tipo acidente categ	Target = 0	Target = 1
Colisão	1.677	599
Saída de leito carroçável	706	141
Tombamento	450	149
Outros	335	56
Atropelamento	84	129
Capotamento	142	20
Engavetamento	99	18
Total	3.493	1.112

LEGENDA

Covariável parece explicar bem a resposta

Covariável parece explicar pouco a resposta

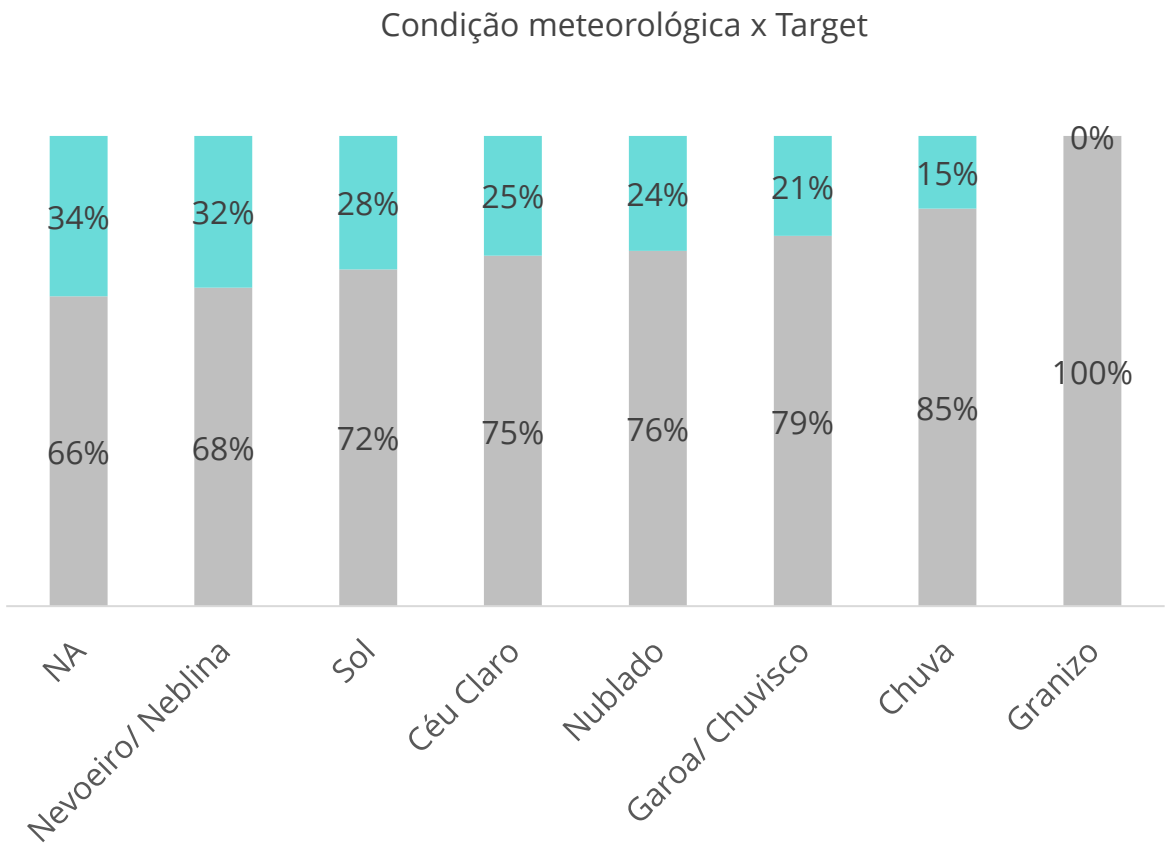
Covariável parece não explicar a resposta

Quando o tipo de acidente é Atropelamento, em 61% desse tipo de ocorrência tem feridos graves ou mortos, bem destoante dos demais tipos de acidentes.

@2020 FIA LABDATA. Copyright all rights reserved.

5.ii. Análise detalhada

ANÁLISE EXPLORATÓRIA | BIVARIADA



Condição meteorológica	Target = 0	Target = 1
Céu Claro	2.028	693
Nublado	517	167
Chuva	574	105
Sol	222	88
Garoa/ Chuvisco	74	20
NA	56	29
Nevoeiro/ Neblina	21	10
Granizo	1	0
Total	3.493	1.112

LEGENDA

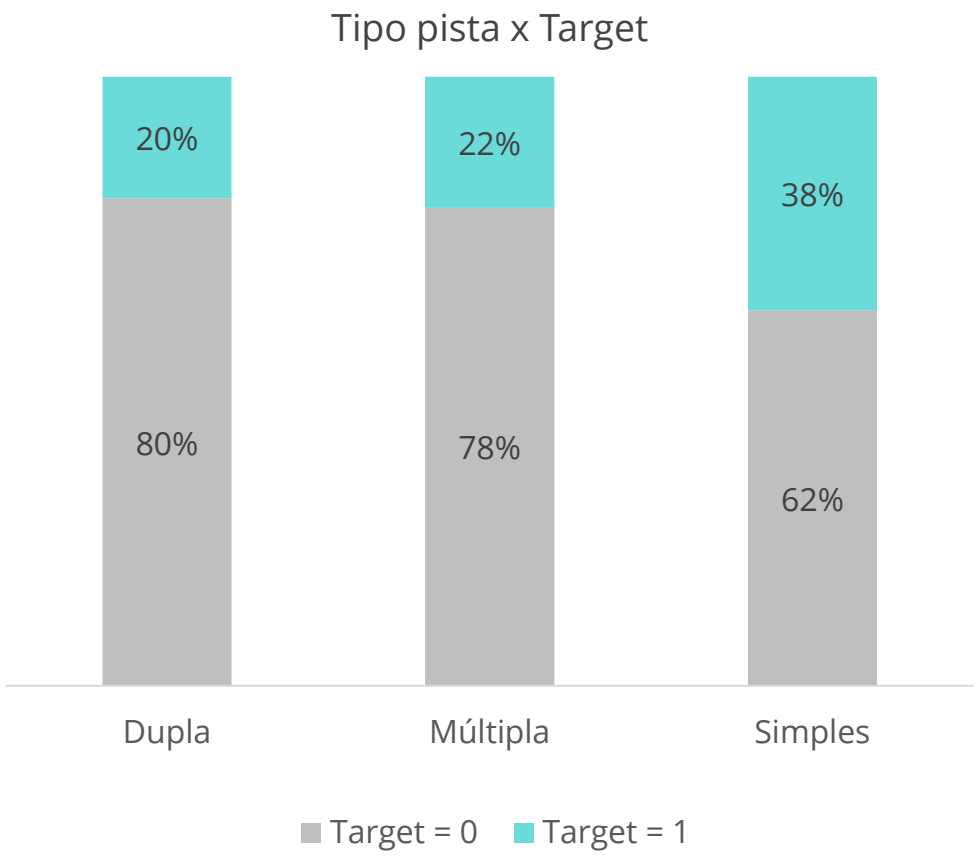
- Covariável parece explicar bem a resposta
- Covariável parece explicar pouco a resposta
- Covariável parece não explicar a resposta

Quando a condição meteorológica é Nevoeiro/ Neblina 32% dessas ocorrências tem ferido graves ou mortos, porém o Missing value é o top 1 , essa variável foi removida no modelo final, pois parecia explicar pouco a resposta.

@2020 FIA LABDATA. Copyright all rights reserved.

5.ii. Análise detalhada

ANÁLISE EXPLORATÓRIA | BIVARIADA



Tipo pista	Target = 0	Target = 1
Dupla	2.738	950
Simples	424	116
Múltipla	331	46
Total	3.493	1.112

LEGENDA

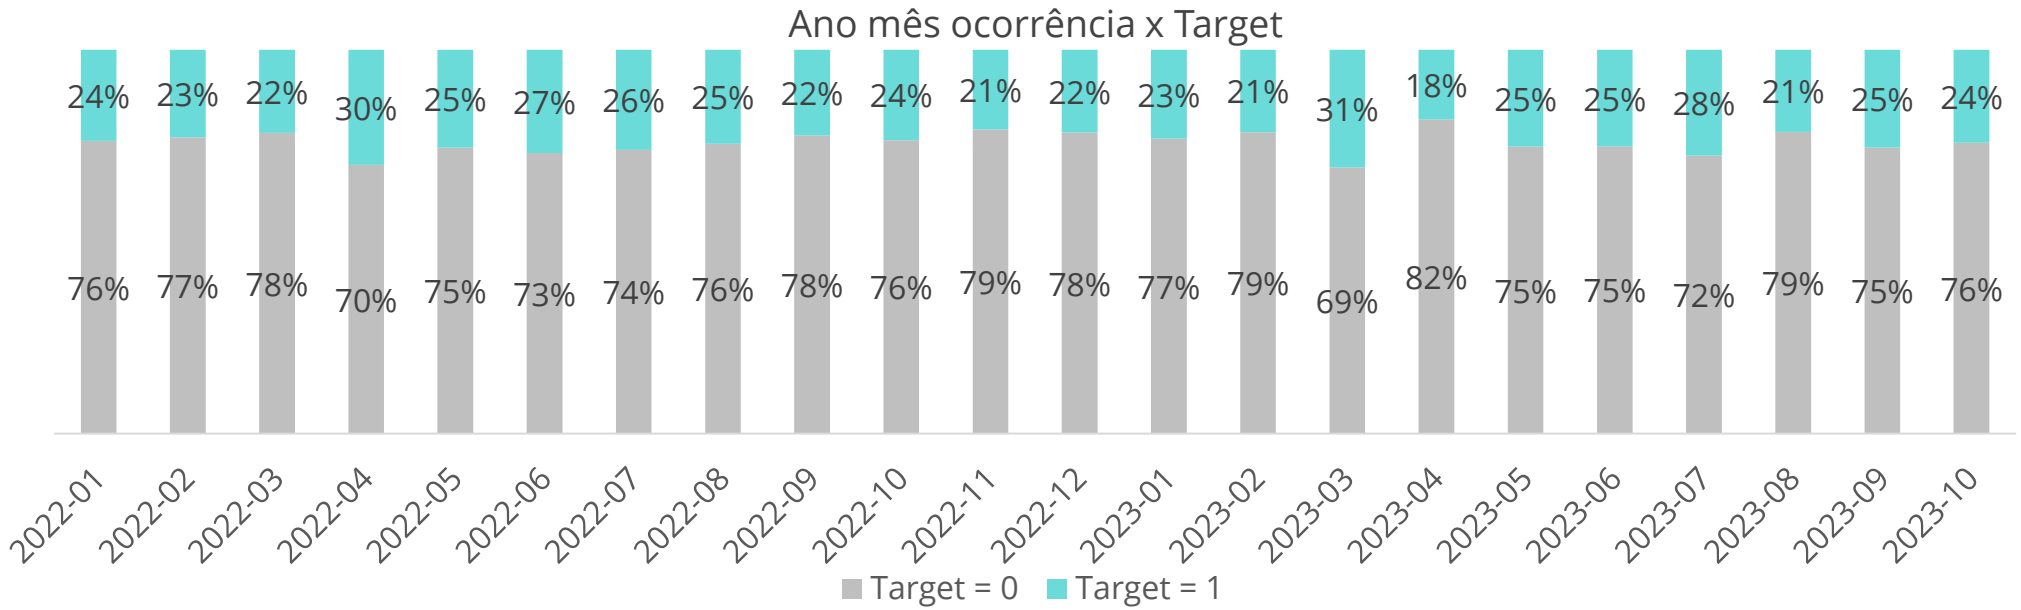
- Covariável parece explicar bem a resposta
- Covariável parece explicar pouco a resposta
- Covariável parece não explicar a resposta

Quando o tipo da pista é Simples parece explicar melhor a resposta do que os demais tipos de pista

@2020 FIA LABDATA. Copyright all rights reserved.

5.ii. Análise detalhada

ANÁLISE EXPLORATÓRIA | BIVARIADA



LEGENDA

- Covariável parece explicar bem a resposta
- Covariável parece explicar pouco a resposta
- Covariável parece não explicar a resposta

Ano_mes	01/22	02/22	03/22	04/22	05/22	06/22	07/22	08/22	09/22	10/22	11/22	12/22	01/23	02/23	03/23	04/23	05/23	06/23	07/23	08/23	09/23	10/23
Target = 0	164	132	130	140	158	136	170	151	150	156	168	207	163	150	145	194	154	152	168	169	164	172
Target = 1	51	39	36	60	54	50	60	49	43	48	44	57	49	41	64	43	52	51	64	46	56	55
Total	215	171	166	200	212	186	230	200	193	204	212	264	212	191	209	237	206	203	232	215	220	227

Ao longo do histórico de jan/22 a out/23 em média 24%(51) das ocorrências possuem feridos graves ou mortos, os únicos meses mais destoantes são mar/23 com 31% e abr/22 com 30%, não parece explicar a resposta.

@2020 FIA LABDATA. Copyright all rights reserved.

6. Modelagem com Estatística Tradicional – Regressão Logística

O desempenho do modelo, tanto nas bases de treino como de teste, apresentou um acerto preditivo satisfatório, de 62% no percentual geral de classificação correta. O percentual de acerto do evento de ocorrências com feridos graves ou mortos ficou em torno de 63% e 67%, já para eventos que não tem feridos graves ou mortos o acerto foi de 60% e 61%. As base de treino e validação apresentaram resultados similares, já na base out-of-time embora ainda satisfatório houve uma perda na qualidade do modelo, o que gera indicio de mudanças no comportamento do público da base.

Indicador	Base de Treino	Base de Teste	Base out-of-time (nov/23)
Acurácia	0,62	0,62	0,58
Sensibilidade	0,63	0,67	0,60
Especificidade	0,61	0,60	0,57
KS	0,24	0,30	0,29
AUC	0,67	0,70	0,65

@2020 FIA LABDATA. Copyright all rights reserved.

6. Modelagem com Estatística Tradicional – Regressão Logística

O total de ocorrências esperado de acidentes graves de trânsito na BR381 em MG são de 334 na base teste. Para calculo do custo operacional foi levado em consideração o TP(True Positive) o quanto o modelo acertou, FN(Fals Negative) o quanto era esperado mas o modelo não identificou e o TP(False Positive) o tanto que o modelo acabou predizendo como o evento porém não era de fato.

Custo médio gasto com acidente de trânsito na rodovia é de **R$2.600 por ocorrência**, em casos de ocorrências que não foram prevista o **custo de reparo** é mais alto sendo de **R$3000 por ocorrência** e **o custo de prevenção**, ou seja, no do acidente previsto que não ocorreu é de **R$400 por ocorrência**

Logo o custo foi calculado da seguinte maneira:

Custo sem o modelo (TP + FN) * custo médio gasto
(108+220)*R$2.600 = R$852.800

Custo com o modelo (220*R$2.600)+(108*R$3.000)+(421*R$400) = 572.000 + 324.000 + 168.400 = R$1.064.400

Economia efetiva Custo com o modelo - Custo sem o modelo
R$1.064.400 - R$852.800 = R$211.600

Com a aplicação do modelo tem um **acréscimo de R$211.600 no custo** devido ao volume mais alto em **falso positivo**, porém como se trata de uma situação delicada onde envolve vítimas que podem ser ou não fatais, optamos por dar mais aderência a assertividade da **sensibilidade,** considerando que esse acréscimo possa ser revertido em investimento.

@2020 FIA LABDATA. Copyright all rights reserved.

7.i. Modelagem Algoritmos de Inteligência Artificial

Machine Learning

Etapas	Modelo 1 ponto de corte padrão	Modelo 2 ponto de corte(maximiza Sensibilidade)	Modelo 3 ponto de corte(maximiza Sensibilidade e melhores parâmetros)	Modelo 4 ponto de corte(maximiza Sensibilidade e melhores parâmetros)	Modelo 5 ponto de corte(maximiza Sensibilidade e melhores parâmetros)
Algoritmo	Regressão Logística	Regressão Logística	Regressão Logística	CatBoost	XGBoost
Base Treino e Teste	70% (3.223) treino e 30% (1.382) Teste	70% (3.223) treino e 30% (1.382) Teste	70% (3.223) treino e 30% (1.382) Teste	70% (3.223) treino e 30% (1.382) Teste	70% (3.223) treino e 30% (1.382) Teste
Pre processamento	OneHotEncoder,Scaler, MeanMedianImputer, Categorical	OneHotEncoder,Scaler, MeanMedianImputer, Categorical	OneHotEncoder,Scaler, MeanMedianImputer, Categorical	OneHotEncoder, MeanMedianImputer, Categorical	OneHotEncoder, MeanMedianImputer, Categorical
Ponto de Corte	50%	25% (maximiza sensibilidade)	47% (maximiza sensibilidade)	21% (maximiza sensibilidade)	58% (maximiza sensibilidade)
Cross Validation StratifiedKFold	StratifiedKFold(n_splits=5)	StratifiedKFold(n_splits=5)	StratifiedKFold(n_splits=5)	StratifiedKFold(n_splits=5)	StratifiedKFold(n_splits=5)
Melhores parâmetros	------	------	'l2', intercept, class_weight': 'balanced', 'logit__C': 100	learning_rate': 0.1, 'l2_leaf_reg': 5, 'iterations': 200, 'depth': 4, 'border_count': 64	'subsample': 1.0, scale_pos_weight': 5, 'reg_lambda': 5, 'n_estimators': 200, 'max_depth': 7, 'learning_rate': 0.01, 'gamma': 0.5, 'colsample_bytree': 0.6
Acurácia	77% treino | 77% teste	55% treino | 55% teste	58% treino | 58% teste	59% treino | 56% teste	59% treino | 55% teste
Sensibilidade	13% treino | 13% teste	72% treino | 75% teste	70% treino | 71% teste	77% treino | 71% teste	79% treino | 70% teste
Especificidade	97% treino | 98% teste	50% treino | 49% teste	54% treino | 54% teste	53% treino | 52% teste	52% treino | 51% teste
Precision	61% treino | 67% teste	31% treino | 32% teste	33% treino | 33% teste	34% treino | 32% teste	34% treino | 31% teste
F1	21% treino |21% teste	42% treino | 45% teste	44% treino | 45% teste	48% treino | 44% teste	48% treino | 43% teste
AUC	67% treino |68% teste	67% treino |68% teste	68% treino | 68% teste	74% treino | 67% teste	73% treino | 67% teste
Conclusão	Sensibilidade extremamente baixo	Sensibilidade satisfatória porém especificidade baixo	Sensibilidade satisfatória e especificidade aceitável	Sensibilidade satisfatória e especificidade aceitável porém modelo demorou para rodar	Sensibilidade boa, porém leve perda em teste e especificidade

@2020 FIA LABDATA. Copyright all rights reserved.

7.i. Modelagem Algoritmos de Inteligência Artificial

O total de ocorrências esperado de acidentes graves de trânsito na BR381 em MG são de 334 na base teste. Para calculo do custo operacional foi levado em consideração o TP(True Positive) o quanto o modelo acertou, FN(Fals Negative) o quanto era esperado mas o modelo não identificou e o TP(False Positive) o tanto que o modelo acabou predizendo como o evento porém não era de fato.

Custo médio gasto com acidente de trânsito na rodovia é de **R$2.600 por ocorrência**, em casos de ocorrências que não foram prevista o **custo de reparo** é mais alto sendo de **R$3000 por ocorrência** e **o custo de prevenção**, ou seja, no do acidente previsto que não ocorreu é de **R$400 por ocorrência**

Logo o custo foi calculado da seguinte maneira:

Custo sem o modelo (TP + FN) * custo médio gasto
(236+98)*R$2.600 = R$868.400

Custo com o modelo (236*R$2.600)+(98*R$3.000)+(479*R$400) = 613.600 + 294.000 + 191.600 = 1.099.200

Economia efetiva Custo sem o modelo – Custo com o modelo
R$1.099.200 – R$868.400 = R$230.800

Com a aplicação do modelo tem um **acréscimo de R$230.800 no custo** devido ao volume mais alto em **falso positivo**, porém como se trata de uma situação delicada onde envolve vítimas que podem ser ou não fatais, optamos por dar mais aderência a assertividade da **sensibilidade,** considerando que esse acréscimo possa ser revertido em investimento.

@2020 FIA LABDATA. Copyright all rights reserved.

7.ii. Arquitetura Algoritmos de Inteligência Artificial

Deep Learning – Redes Densas


```python
from keras.layers import Dense
from keras.callbacks import EarlyStopping
import tensorflow as tf
import numpy as np
import random

# Fixando a semente de aleatoriedade

seed = 42
random.seed(seed)
np.random.seed(seed)
tf.random.set_seed(seed)

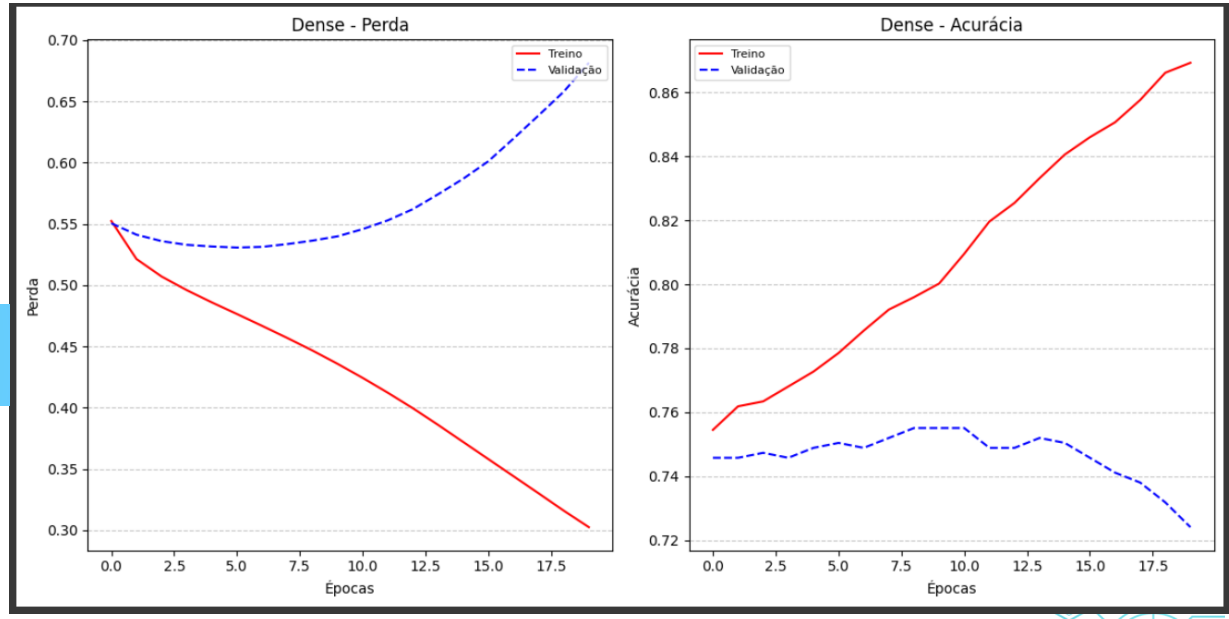
# Criar o modelo
dense_model = Sequential()
dense_model.add(Dense(64, input_dim=X_train_transformed.shape[1], activation='relu'))
dense_model.add(Dense(32, activation='relu'))
dense_model.add(Dense(1, activation='sigmoid'))

dense_model.compile(optimizer='adam', loss='binary_crossentropy', metrics=['accuracy'])

dense_history = dense_model.fit(X_train_transformed, y_train, validation_split=0.2, epochs=20, batch_size=32)
```

Arquitetura

Avaliação LOSS e Acurácia



@2020 FIA LABDATA. Copyright all rights reserved.

7.ii. Arquitetura Algoritmos de Inteligência Artificial

Deep Learning – Redes Densas Completa


```python
from keras.models import Sequential
from keras.layers import Dense, Dropout, BatchNormalization, Input
from keras import regularizers
from keras.optimizers import RMSprop, Adam  # Adicionando Adam aqui
from keras.callbacks import EarlyStopping
import tensorflow as tf
import numpy as np
import random

# Fixando a semente de aleatoriedade
seed = 42
random.seed(seed)
np.random.seed(seed)
tf.random.set_seed(seed)
# Criar o modelo
dense_model = Sequential()
dense_model.add(Input(shape=(X_train_transformed.shape[1],))) # Camada de entrada com forma definida a partir dos dados de treino
dense_model.add(Dense(128, activation='relu', kernel_regularizer=regularizers.l2(0.0001)))
dense_model.add(BatchNormalization()) # BatchNormalization para estabilizar e acelerar o treinamento
dense_model.add(Dropout(0.5))
dense_model.add(Dense(64, activation='relu', kernel_regularizer=regularizers.l2(0.0001)))
dense_model.add(BatchNormalization())
dense_model.add(Dropout(0.5))
dense_model.add(Dense(32, activation='relu', kernel_regularizer=regularizers.l2(0.0001)))
dense_model.add(Dense(1, activation='sigmoid'))

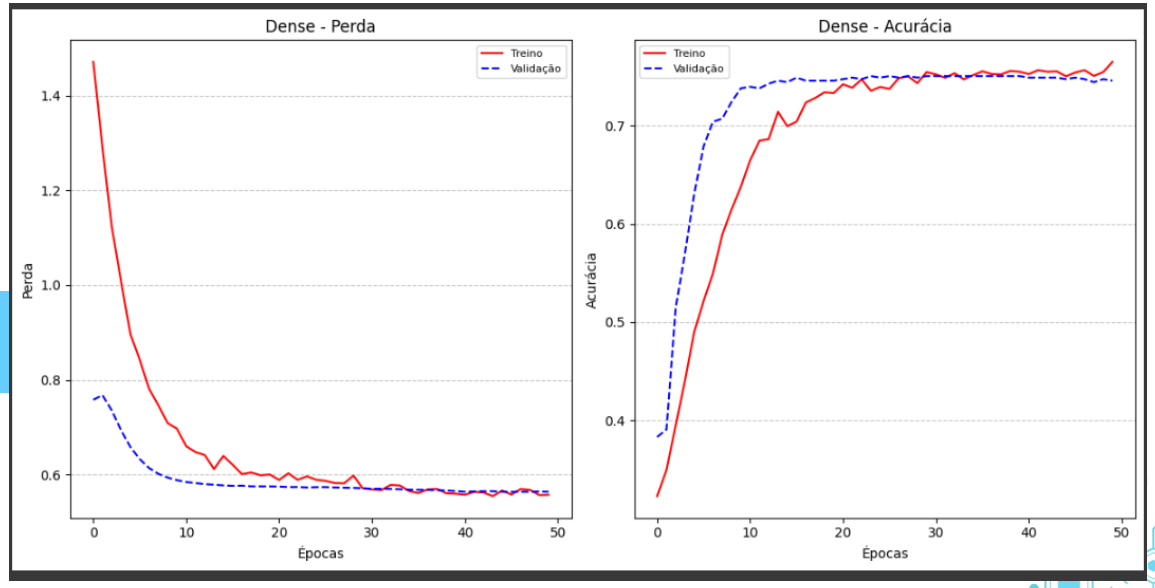
# Compilar o modelo com um otimizador diferente
dense_model.compile(optimizer=Adam(learning_rate=0.0001), loss='binary_crossentropy', metrics=['accuracy'])
# Treinar o modelo com EarlyStopping
early_stopping = EarlyStopping(monitor='val_loss', patience=10, restore_best_weights=True)

dense_history = dense_model.fit(
    X_train_transformed, y_train,
    validation_split=0.2,
    epochs=50,
    batch_size=32,
    callbacks=[early_stopping]
)

# Avaliar o modelo no conjunto de teste
test_loss, test_accuracy = dense_model.evaluate(X_oot_transformed, y_oot)
print(f'Test Loss: {test_loss}, Test Accuracy: {test_accuracy}')
```

Arquitetura

Avaliação LOSS e Acurácia



@2020 FIA LABDATA. Copyright all rights reserved.

7.ii. Arquitetura Algoritmos de Inteligência Artificial

Deep Learning – Redes CNN Completa


```python
import random
import numpy as np
import tensorflow as tf
from keras.models import Sequential
from keras.layers import Conv1D, MaxPooling1D, Flatten, Dense, Dropout, BatchNormalization
from keras.callbacks import EarlyStopping
from keras.optimizers import Adam
import matplotlib.pyplot as plt

# Fixando a semente de aleatoriedade para reprodutibilidade
seed = 42
random.seed(seed)
np.random.seed(seed)
tf.random.set_seed(seed)

# Redimensionar os dados de entrada para 3D: (n_amostras, comprimento_sequência, 1)
X_train_cnn = np.expand_dims(X_train_transformed, axis=2)
X_oot_cnn = np.expand_dims(X_oot_transformed, axis=2)

# Definir a arquitetura da CNN com Batch Normalization e Dropout
cnn_model = Sequential()
cnn_model.add(Conv1D(128, kernel_size=2, activation='relu', input_shape=(X_train_cnn.shape[1], 1)))
cnn_model.add(BatchNormalization())  # Adiciona Batch Normalization para estabilizar o aprendizado
cnn_model.add(MaxPooling1D(pool_size=2))
cnn_model.add(Conv1D(64, kernel_size=2, activation='relu'))
cnn_model.add(Dropout(0.5))  # Adiciona Dropout para evitar overfitting
cnn_model.add(MaxPooling1D(pool_size=2))
cnn_model.add(Flatten())
cnn_model.add(Dense(32, activation='relu'))
cnn_model.add(Dense(1, activation='sigmoid'))

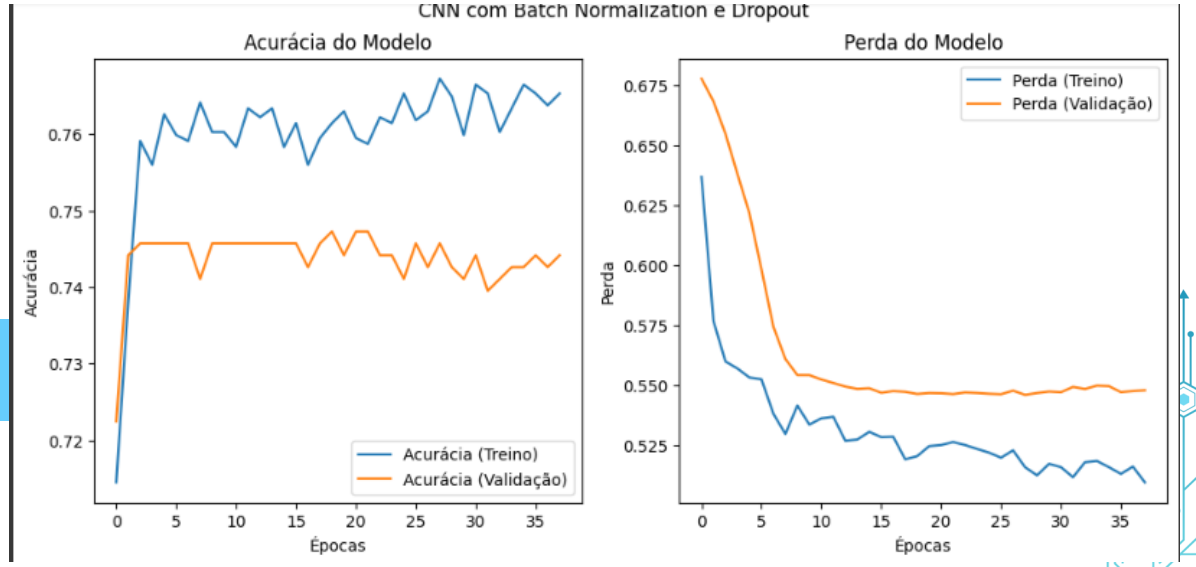
# Compilar o modelo
cnn_model.compile(optimizer=Adam(learning_rate=0.0001), loss='binary_crossentropy', metrics=['accuracy'])

# Treinar o modelo com EarlyStopping
early_stopping = EarlyStopping(monitor='val_loss', patience=10, restore_best_weights=True)

cnn_history = cnn_model.fit(
    X_train_cnn, y_train,
    validation_split=0.2,
    epochs=50,
    batch_size=32,
    callbacks=[early_stopping]
)
```

Arquitetura

Avaliação LOSS e Acurácia



@2020 FIA LABDATA. Copyright all rights reserved.

7.ii. Arquitetura Algoritmos de Inteligência Artificial

Deep Learning – Redes LSTM Completa


```python
import random
import numpy as np
import tensorflow as tf
from keras.models import Sequential
from keras.layers import LSTM, Dense, Dropout
from keras.callbacks import EarlyStopping

# Fixando a semente de aleatoriedade para reprodutibilidade
seed = 42
random.seed(seed)
np.random.seed(seed)
tf.random.set_seed(seed)

# Definir o número de time_steps (cada ponto é independente neste caso)
time_steps = 1

# Redimensionar os dados de entrada para 3D: (n_amostras, time_steps, n_features)
X_train_rnn = X_train_transformed.to_numpy().reshape((X_train_transformed.shape[0], time_steps, X_train_transformed.shape[1]))
X_oot_rnn = X_oot_transformed.to_numpy().reshape((X_oot_transformed.shape[0], time_steps, X_oot_transformed.shape[1]))

# Definir a arquitetura da RNN com LSTM e Dropout
rnn_model = Sequential()
rnn_model.add(LSTM(100, input_shape=(time_steps, X_train_transformed.shape[1])))  # Aumentado para 50 neurônios
rnn_model.add(Dropout(0.5))  # Adicionando Dropout para evitar overfitting
rnn_model.add(Dense(32, activation='relu'))  # Camada densa adicional
rnn_model.add(Dense(1, activation='sigmoid'))  # Saída binária para classificação

# Compilar o modelo
rnn_model.compile(optimizer='adam', loss='binary_crossentropy', metrics=['accuracy'])

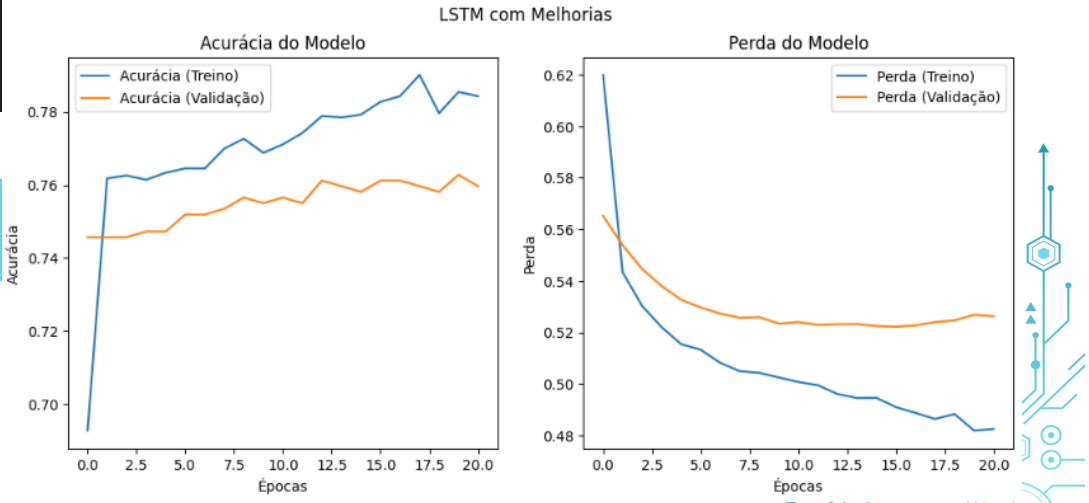
# EarlyStopping para evitar overfitting e interromper o treinamento cedo se a validação parar de melhorar
early_stopping = EarlyStopping(monitor='val_loss', patience=5, restore_best_weights=True)

# Treinar o modelo com EarlyStopping e 50 épocas
rnn_history = rnn_model.fit(X_train_rnn, y_train, validation_split=0.2, epochs=50, batch_size=64, callbacks=[early_stopping])  # Aumentado para 50 épocas e batch_size 64

# Plotar o histórico de treinamento
plot_training_history(rnn_history, 'LSTM com Melhorias')
```

Arquitetura

Avaliação LOSS e Acurácia



@2020 FIA LABDATA. Copyright all rights reserved.

7.ii. Modelagem Algoritmos de Inteligência Artificial

Deep Learning

Etapas	Modelo 1	Modelo 2	Modelo 3	Modelo 4
Algoritmo	Redes Densas	Redes Densas	CNN	LSTM
Base Treino e Teste	70% (3.223) treino e 30% (1.382) Teste	70% (3.223) treino e 30% (1.382) Teste	70% (3.223) treino e 30% (1.382) Teste	70% (3.223) treino e 30% (1.382) Teste
Stratity e Random_state	X	X	X	X
Features	10 categóricas 3 númericas	10 categóricas 3 númericas	10 categóricas 3 númericas	10 categóricas 3 númericas
Pre processamento	OneHotEncoder,Scaler, MeanMedianImputer, Categorical	OneHotEncoder,Scaler, MeanMedianImputer, Categorical	OneHotEncoder,Scaler, MeanMedianImputer, Categorical	OneHotEncoder,Scaler, MeanMedianImputer, Categorical
Quantidade camadas	3	9	9	4
Regularização| Normalização e dropout	------	l2(0.0001) |batch normalization | 0.5	batch normalization | 0.5 |MaxPooling	0.5
Early_stopping	------	10	10	5
Função na camada de saída	Sigmoid	Sigmoid	Sigmoid	Sigmoid
Epochs | Batch Size	20 | 32	50 | 32	50 | 32	50 | 64
Ponto de corte	50%	22%	22%	22%
Otimizador	adam	adam	adam	adam
Função de custo	binary_crossentropy	binary_crossentropy	binary_crossentropy	binary_crossentropy
Loss	30% treino | 68% teste	56% treino | 56% teste	52% treino | 55% teste	48% treino | 53% teste
Acuracidade	86% treino | 71% teste	63% treino | 58% teste	53% treino | 52% teste	68% treino | 64% teste
Sensibilidade	61% treino | 27% teste	70% treino | 56% teste	77% treino | 74% teste	64% treino | 56% teste
Especificidade	95% treino | 85% teste	61% treino | 59% teste	45% treino | 46% teste	69% treino | 67% teste
F1	68% treino | 31% teste	48% treino | 39% teste	44% treino | 42% teste	49% treino | 43% teste
AUC	88% treino | 60% teste	71% treino | 62% teste	68% treino | 65% teste	72% treino | 66% teste
Conclusão	Overfting	Overfting	Equilibrado	Overfting

@2020 FIA LABDATA. Copyright all rights reserved.

7.ii. Modelagem Algoritmos de Inteligência Artificial

MODELAGEM COM DEEP LEARNING| CUSTO OPERACIONAL

O total de ocorrências esperado de acidentes graves de trânsito na BR381 em MG são de 334 na base teste. Para calculo do custo operacional foi levado em consideração o TP(True Positive) o quanto o modelo acertou, FN(Fals Negative) o quanto era esperado mas o modelo não identificou e o TP(False Positive) o tanto que o modelo acabou predizendo como o evento porém não era de fato.

Custo médio gasto com acidente de trânsito na rodovia é de **R$2.600 por ocorrência**, em casos de ocorrências que não foram prevista o **custo de reparo** é mais alto sendo de **R$3000 por ocorrência** e **o custo de prevenção**, ou seja, no do acidente previsto que não ocorreu é de **R$400 por ocorrência**

Logo o custo foi calculado da seguinte maneira:

Custo sem o modelo (TP + FN) * custo médio gasto
(246+88)*R$2.600 = R$868.400

Custo com o modelo (246*R$2.600)+(88*R$3.000)+(571*R$400) = 639.600 + 264.000 + 228.400 = 1.132.000

Economia efetiva Custo sem o modelo – Custo com o modelo
R$1.132.000 – R$868.400 = R$263.600

Com a aplicação do modelo tem um **acréscimo de R$263.600 no custo** devido ao volume mais alto em **falso positivo**, porém como se trata de uma situação delicada onde envolve vítimas que podem ser ou não fatais, optamos por dar mais aderência a assertividade da **sensibilidade,** considerando que esse acréscimo possa ser revertido em investimento.

Detalhes das análises

@2020 FIA LABDATA. Copyright all rights reserved.

8. Modelagem Algoritmos Escolhidos

Comparativo

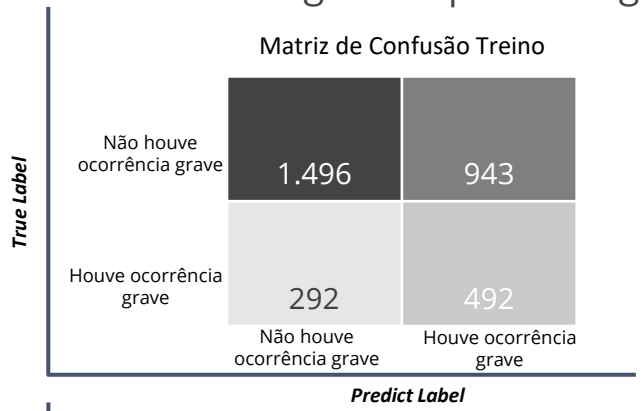
Etapas	Regressão Logística ET	Regressão Logística ML	Redes CNN - DL
Algoritmo	Regressão Logísitca	Regressão Logística	CNN
Base Treino e Teste	70% (3.223) treino e 30% (1.382) Teste	70% (3.223) treino e 30% (1.382) Teste	70% (3.223) treino e 30% (1.382) Teste
Stratity e Random_state	----	X	X
Features	3 categóricas 2 númericas	3 categóricas 2 númericas	10 categóricas 3 números
Pre processamento	Remoção de missing value | Dummies	OneHotEncoder,Scaler, MeanMedianImputer, Categorical	OneHotEncoder,Scaler, MeanMedianImputer, Categorical
Ponto de corte	22%	47% (maximiza sensibilidade)	22%
Regularização (L2)	----	X	batch normalization |dropout 0.5 |MaxPooling
Acuracidade Treino e Teste	62% | 62%	58% | 58%	53% treino | 52% teste
Sensibilidade Treino e Teste	63% | 67%	70% | 71%	77% treino | 74% teste
Especificidade Treino e Teste	61% | 60%	54% | 54%	45% treino | 46% teste
Loss	---	---	52% treino | 55% teste
Conclusão	Equilibrado	Equilibrado	Equilibrado

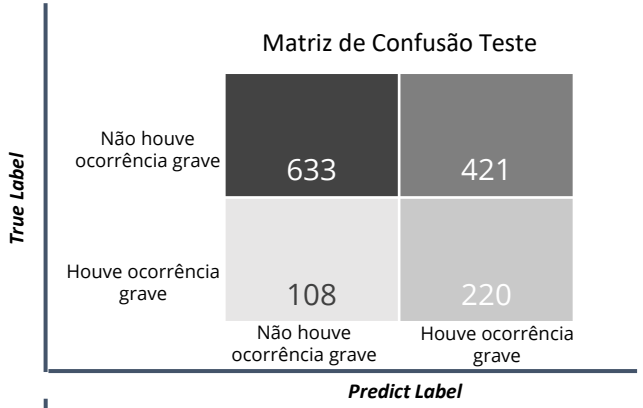
@2020 FIA LABDATA. Copyright all rights reserved.

8. Modelagem Algoritmos de Inteligência Artificial – Comparativo

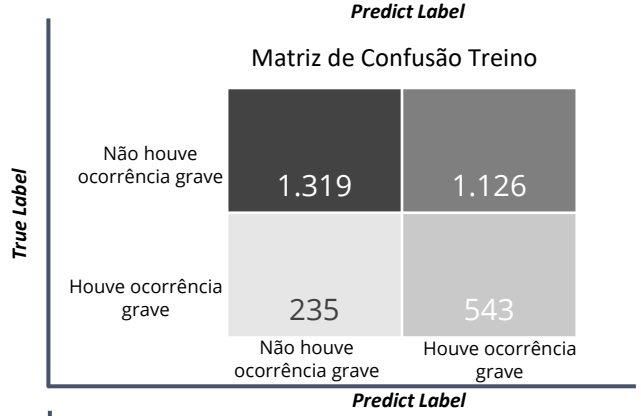
Estatística Tradicional X Machine Learning X Deep Learning

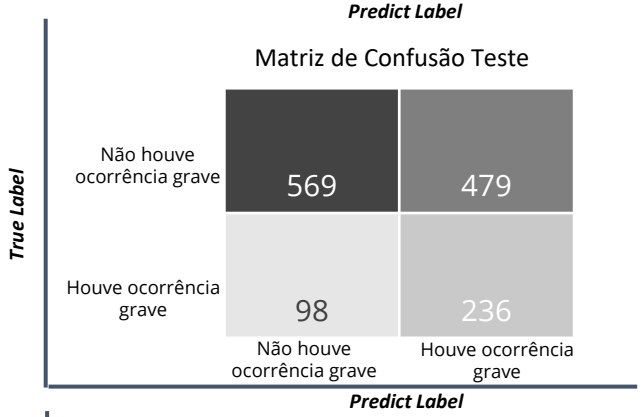
Regressão Logística – ET
Modelo 1 (Ponto de corte 22%)



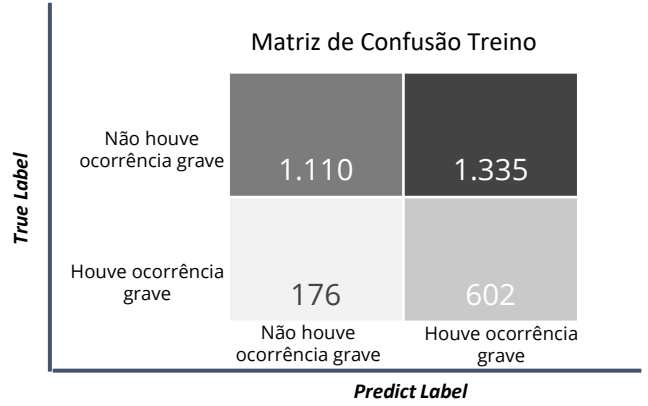


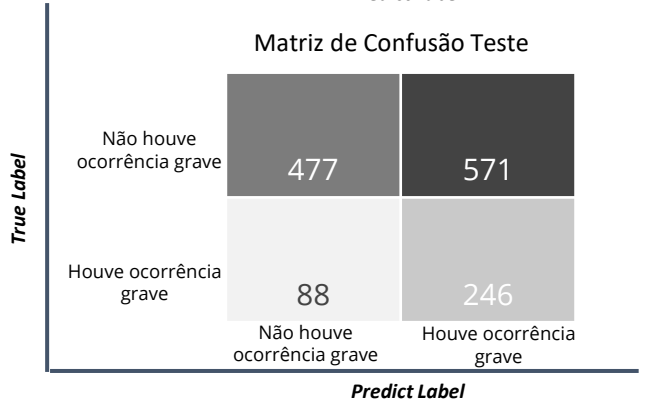
Regressão Logística – ML
Modelo 2 (Ponto de corte 47%)





Redes CNN – DL
Modelo 3 (Ponto de corte 22%)





O **Modelo 3 (Regressão Logística – ML)** foi o escolhido para este problema de negócio de classificação , **devido a performance em Acurácia e Sensibilidade**, o desempenho em **treino e teste**. Porém vale ressaltar o ponto de atenção do **Falso positivo**. Porém demos preferência para a assertividade do **Target de interesse 1**.

@2020 FIA LABDATA. Copyright all rights reserved.

OBRIGADA!